ایجنت چه چیزی را باید فراموش کند؟ تحلیل رقابتی حذف حافظه در ایجنت‌های مبتنی بر مدل زبانی بزرگ

نویسندگان: امیرحسین خلیفه[1]*، مهدی غلامی[2]

[1] پژوهشگر مستقل، تهران، ایران [2] دانشگاه آزاد اسلامی، واحد کرج، کرج، ایران *نویسنده مسئول: Amirkhalife.biz@gmail.com

کد و داده: https://github.com/AmirHosseinkhalife/agent-memory-eviction/tree/main/agent-memory-eviction

چکیده

ایجنت‌های مبتنی بر مدل زبانی بزرگ (LLM) به‌طور فزاینده‌ای به حافظه خارجی پایدار متکی‌اند، اما هر حافظه عملی محدود است و باید تصمیم بگیرد چه چیزی را فراموش کند. ادبیاتی که به‌سرعت در حال گسترش است، روش‌های ابتکاری (heuristic) حذف را بر پایه تازگی، زوال و امتیازدهی اهمیت پیشنهاد می‌کند، اما هیچ‌یک با آنچه *قابل‌دستیابی* است سنجیده نشده و بنابراین معلوم نیست چه مقدار جای پیشرفت باقی مانده است. ما مدیریت حافظه ایجنت را به‌صورت **مسئله حذف حافظه ایجنت (AMEP)** صورت‌بندی می‌کنیم؛ مسئله‌ای آنلاین که از سه جهت با کش کلاسیک تفاوت دارد: حذف **برگشت‌ناپذیر** است، آیتم‌ها **اندازه و ارزش ناهمگن** دارند و برخی آیتم‌ها **نادر اما حیاتی**‌اند. ثابت می‌کنیم که قاعده Belady، که برای صفحه‌بندی بهینه است، تحت برگشت‌ناپذیری می‌تواند به‌طور دلخواه بد عمل کند؛ مسئله آفلاین در حالت کلی NP-سخت است اما برای اندازه‌های یکسان با جریان کمینه‌هزینه حل‌پذیر است؛ **هیچ سیاست آنلاینی، حتی تصادفی، در بدترین حالت رقابتی نیست**؛ و هر سیاست **بی‌توجه به ارزش** (LRU، LFU، FIFO) حتی تحت یک مدل تصادفی ملایم می‌تواند به کسر B/n از مطلوبیت قابل‌دستیابی تنزل یابد. در سوی مثبت، تحت مدل دسترسی مجدد مستقل، شاخص ارزش–نرخ–اندازه $(1 - s_{\max}/B)$-رقابتی است؛ با ارزش‌های پیش‌بینی‌شده، این سیاست به معنای الگوریتم‌های همراه با پیش‌بینی، سازگار (consistent) و هموار (smooth) است، اما هیچ سیاستی نمی‌تواند مقاوم (robust) باشد. همچنین نشان می‌دهیم که **بهای پیش‌آگاهی** (price of clairvoyance)، یعنی فاصله بهترین سیاست آنلاین تا بهینه پس‌نگر، در درخواست‌های پراکنده به‌صورت $\Theta(\log n / \log\log n)$ رشد می‌کند. **MemSim** را منتشر می‌کنیم: شبیه‌سازی متن‌باز همراه با اوراکل ILP دقیق. دوازده سیاست را روی ۲۵۰ نمونه مصنوعی و روی **مکالمات بلندمدت واقعی از LoCoMo** (۵,۸۸۲ نوبت گفتگو، ۱,۵۳۵ پرسش، ۴۴۰ نمونه حل‌شده با اوراکل) ارزیابی می‌کنیم، در حالی که اهمیت هر نوبت به‌صورت آنلاین توسط یک LLM پیش‌بینی می‌شود. در بارهای کاری مصنوعی، روش‌های ابتکاری رایج به ۳۹ تا ۷۸ درصد بهینه پیش‌آگاه می‌رسند، در مقابل ۸۲٫۴ درصد برای سیاست شاخص‌محور ما همراه با فشرده‌سازی؛ و سیاست‌های مبتنی بر تازگی تنها ۱۸ تا ۳۲ درصد واقعیت‌های حیاتی را به یاد می‌آورند، در مقابل ۹۷ تا ۹۹ درصد. در مکالمات واقعی، اهمیت پیش‌بینی‌شده توسط LLM (با AUC برابر ۰٫۸۳ برای نوبت‌هایی که بعداً لازم می‌شوند) مطلوبیت سیاست‌های آگاه از ارزش را ۱۲ تا ۲۵ واحد درصد افزایش

می‌دهد، سیاست‌های بی‌توجه به ارزش به‌سختی از حذف تصادفی بهتر عمل می‌کنند (۳۰ تا ۳۱ درصد در برابر ۲۵ درصد بهینه در بودجه ۱۰ درصد)، و فشرده‌سازی آگاه از ارزش با همان بودجه ۲ تا ۵ برابر LRU شواهد نگه می‌دارد. نتایج ما نخستین نقطه مرجع اصولی برای ارزیابی حافظه ایجنت را فراهم می‌کند.

کلیدواژه‌ها: ایجنت‌های LLM، حافظه ایجنت، الگوریتم‌های آنلاین، تحلیل رقابتی، کش، فراموشی، الگوریتم Belady

۱. مقدمه

۱.۱ انگیزه

ایجنت‌های LLM از مکالمات منفرد به سمت استقرارهای بلندمدت حرکت می‌کنند: دستیارهای شخصی که ماه‌ها همراه کاربرند، ایجنت‌های برنامه‌نویسی که در سراسر تاریخچه یک مخزن کد کار می‌کنند، و ایجنت‌های سازمانی که به تیم‌های کامل خدمت می‌دهند. چنین ایجنت‌هایی به حافظه‌ای نیاز دارند که از پنجره کانتکست فراتر برود. خانواده‌ای از سامانه‌ها اکنون این را فراهم می‌کنند: MemGPT اطلاعات را بین کانتکست و حافظه خارجی جابه‌جا می‌کند [8]، Generative Agents خاطرات را بر اساس تازگی، اهمیت و ارتباط بازیابی می‌کند [7]، MemoryBank منحنی فراموشی ابینگهاوس را به کار می‌برد [9]، و کتابخانه‌های تولیدی مانند Mem0 [10] و A-Mem [11] حافظه‌های پویا را برای ایجنت‌های مستقر نگه‌داری می‌کنند (برای مرور به [12] رجوع کنید).

هر چنین حافظه‌ای **محدود** است. کیفیت بازیابی با بزرگ شدن حافظه افت می‌کند، بودجه پرامپت مقدار حافظه بازیابی‌شده قابل‌خواندن را محدود می‌کند، هزینه ذخیره‌سازی و embedding با تعداد آیتم‌ها رشد می‌کند، و مقررات حریم خصوصی نگهداری را محدود می‌کند. بنابراین حافظه محدود باید به‌طور پیوسته تصمیم بگیرد **چه چیزی را فراموش کند**. پیامد تصمیم اشتباه ملموس است: مطالعه‌ای اخیر نشان می‌دهد دستیارهای شخصی واقعیت‌های مرتبط با ایمنی، مانند حساسیت غذایی کاربر، را حذف می‌کنند در حالی که محتوای گفتگوی کم‌ارزش را نگه می‌دارند [20].

۱.۲ شکاف پژوهشی

ادبیات فراموشی ایجنت گسترده و رو به رشد است [13–17]، اما تقریباً به‌طور کامل تجربی است: هر مقاله یک روش ابتکاری جدید را با چند روش دیگر روی یک بنچمارک مقایسه می‌کند. آنچه غایب است، یک **نقطه مرجع** است. بدون دانستن بهترین مطلوبیت قابل‌دستیابی در یک بار کاری، بهبود گزارش‌شده از ۶۱ به ۶۴ درصد قابل تفسیر نیست: ممکن است بخش عمده شکاف باقی‌مانده را بسته باشد یا کسری ناچیز از آن را.

نظریه کلاسیک کش منبع طبیعی چنین نقطه مرجعی به نظر می‌رسد. الگوریتم Belady بهینه آفلاین صفحه‌بندی را می‌دهد [1] و تحلیل رقابتی سیاست‌های آنلاین مانند LRU را مشخص می‌کند [2]. اما چنان‌که نشان می‌دهیم، این نتایج **منتقل نمی‌شوند**. کش کلاسیک فرض می‌کند صفحه حذف‌شده را می‌توان با هزینه‌ای از حافظه کندتر دوباره آورد. حافظه ایجنت متفاوت است: وقتی خاطره‌ای فراموش شد، **از دست رفته** است؛ ایجنت نمی‌تواند مکالمه‌ای از سه ماه پیش را که

تصمیم گرفته نگه ندارد دوباره بخواند. آیتم‌ها همچنین در اندازه و ارزش چندین مرتبه با هم تفاوت دارند، و باارزش‌ترین آیتم‌ها اغلب کم‌دسترسی‌ترین‌اند.

۱.۳ دستاوردها

1. **صورت‌بندی.** *مسئله حذف حافظه ایجنت* (AMEP) را تعریف می‌کنیم: مسئله‌ای آنلاین با حذف برگشت‌ناپذیر، اندازه و ارزش متغیر آیتم‌ها و فرایند درخواست برون‌زا (بخش ۳).
2. **ساختار آفلاین.** نشان می‌دهیم که قاعده «دورترین در آینده» Belady تحت برگشت‌ناپذیری می‌تواند به‌طور دلخواه بد باشد (گزاره ۱)، AMEP آفلاین در حالت کلی NP-سخت است و در اندازه‌های یکسان با جریان کمینه‌هزینه در زمان چندجمله‌ای حل می‌شود (قضیه ۱). برای حالت کلی یک اوراکل ILP دقیق ارائه می‌کنیم.
3. **نتایج عدم امکان.** هیچ سیاست آنلاینی، قطعی یا تصادفی، نسبت رقابتی کراندار ندارد (قضیه ۲). هر سیاست بی‌توجه به ارزش، از جمله FIFO، LFU، LRU و منحنی‌های فراموشی، حتی تحت بار کاری تصادفی ملایم می‌تواند به کسر B/n از مطلوبیت قابل‌دستیابی تنزل یابد (قضیه ۳).
4. **سیاستی با ضمانت.** تحت مدل دسترسی مجدد مستقل، سیاست شاخص ارزش–نرخ–اندازه به‌صورت برگشت‌ناپذیر قابل‌پیاده‌سازی و در برابر هر سیاستی که درخواست‌های آینده را پیش‌بینی نمی‌کند $(1 - s_{\max}/B)$-رقابتی است (قضیه ۴). با ارزش‌های پیش‌بینی‌شده، سازگار و هموار است و هیچ سیاستی نمی‌تواند هم‌زمان مقاوم باشد؛ این AMEP را در چارچوب الگوریتم‌های همراه با پیش‌بینی قرار می‌دهد (نتیجه ۱).
5. **بهای پیش‌آگاهی.** فاصله بهترین سیاست آنلاین تا بهینه پس‌نگر را از بالا و پایین کران‌دار می‌کنیم (قضیه ۵) و به‌طور تجربی نشان می‌دهیم که بخش بزرگی از فاصله هر سیاست تا OPT ماهیت اطلاعاتی دارد نه الگوریتمی.
6. **MemSim.** شبیه‌سازی متن‌باز با پنج مولد بار کاری مصنوعی، خط لوله داده واقعی برای LoCoMo [28] با اهمیت پیش‌بینی‌شده توسط LLM، دوازده سیاست، اوراکل آفلاین دقیق و خط لوله آزمایش تکرارپذیر (بخش ۶).
7. **یافته‌های تجربی.** روی ۲۵۰ نمونه مصنوعی و ۴۴۰ نمونه مکالمه واقعی: بهترین روش‌های ابتکاری موجود ۲۲ درصد از مطلوبیت قابل‌دستیابی را بلااستفاده می‌گذارند؛ سیاست‌های بی‌توجه به ارزش واقعیت‌های حیاتی را بیش از حذف تصادفی فراموش می‌کنند؛ اهمیت پیش‌بینی‌شده توسط LLM بزرگ‌ترین اهرم منفرد روی داده واقعی است (۱۲+ تا ۲۵+ واحد)؛ هیچ قاعده حذفی در همه الگوهای دسترسی غالب نیست؛ و فشرده‌سازی آگاه از ارزش در مجموع مؤثرترین مداخله است (بخش ۷).

۱.۴ ساختار مقاله

بخش ۲ کارهای مرتبط را مرور می‌کند. بخش ۳ AMEP را صورت‌بندی می‌کند. بخش ۴ نتایج نظری و بخش ۵ سیاست حاصل را ارائه می‌کند. بخش ۶ MemSim را توصیف می‌کند و بخش ۷ آزمایش‌ها را روی بارهای کاری مصنوعی (۷.۲ تا ۷.۷) و مکالمات واقعی (۷.۸) گزارش می‌دهد و با تحلیل حساسیت (۷.۹) ادامه می‌یابد. بخش‌های ۸ تا ۱۰ به پیامدها، محدودیت‌ها و نتیجه‌گیری می‌پردازند. همه اثبات‌ها در پیوست الف آمده‌اند.

---

۲. پیشینه و کارهای مرتبط

۲.۱ معماری‌های حافظه برای ایجنت‌های LLM

MemGPT [8] پنجره کانتکست را حافظه اصلی و حافظه خارجی را دیسک در نظر می‌گیرد و LLM فراخوانی‌های صفحه‌بندی را صادر می‌کند. Generative Agents [7] جریانی از مشاهدات را ذخیره و با مجموع وزن‌دار تازگی، اهمیت (امتیاز ۱ تا ۱۰ توسط LLM) و ارتباط بازیابی می‌کند. MemoryBank [9] به هر آیتم قدرت حافظه‌ای نسبت می‌دهد که در امتداد منحنی ابینگهاوس زوال می‌یابد و با یادآوری تقویت می‌شود. Mem0 [10] و A-Mem [11] حافظه‌های ساختاریافته و پویا با عملیات استخراج، به‌روزرسانی و ادغام نگه می‌دارند. مروری اخیر [12] این فضا را بر اساس شکل، کارکرد و پویایی حافظه سازمان می‌دهد. این سامانه‌ها تعیین می‌کنند خاطرات *چگونه* ذخیره و بازیابی شوند؛ تصمیم *ظرفیت* را، اگر اصلاً، به‌صورت ابتکاری می‌گیرند. **کار ما مکمل است:** خود تصمیم ظرفیت را تحلیل می‌کنیم و برای هر یک از این سامانه‌ها معیار سنجشی فراهم می‌کنیم.

۲.۲ فراموشی و حذف در حافظه ایجنت

خط دوم پژوهش مستقیماً فراموشی را هدف می‌گیرد. FadeMem [13] زوال الهام‌گرفته از زیست‌شناسی و تعدیل‌شده با اهمیت را به کار می‌برد؛ SF-AMS [14] فراموشی راهبردی روی حافظه ساختاریافته انجام می‌دهد؛ فراموشی انتخابی مبتنی بر گراف [15] گراف‌های حافظه را هرس می‌کند؛ مدل ارزش چندعاملی [16] یاد می‌گیرد چه چیزی را نگه دارد؛ و دیدگاه نرخ–اعوجاج [17] فشرده‌سازی حافظه را به‌صورت مصالحه‌ای بین بودجه و اتلاف اطلاعات می‌بینند. این کارها بهبودهای تجربی را، معمولاً در برابر روش‌های مبنای تازگی یا یکنواخت، گزارش می‌دهند. نزدیک‌ترین کار از نظر روح، [23] است که نشان می‌دهد LRU وقتی مفید بودن هر خاطره با سن به‌صورت نمایی زوال یابد تقریباً بهینه است؛ حالتی خاص که نتایج ما در بار کاری محلیت زمانی تأیید می‌کند (بخش ۷.۲). [24] نیز شکست‌هایی را مستند می‌کند که در آن یک خاطره پیش‌نیاز پیش از آنکه هرگز بازیابی شود حذف می‌شود. **هیچ‌یک از این کارها با بهینه مقایسه نمی‌کند یا برای بارهای کاری عمومی ضمانت بدترین حالت یا توزیعی ارائه نمی‌دهد**؛ دقیقاً همان چیزی که اوراکل و نظریه ما فراهم می‌کند.

۲.۳ کش و حذف KV-Cache در سرویس‌دهی LLM

در سطح سیستم، حذف KV-cache برای استنتاج ایجنت (مانند MemDecay [18]) و جایگزینی prefix-cache [19] به‌طور گسترده مطالعه شده‌اند؛ به‌ویژه [19] نشان می‌دهد LRU روی داده‌های واقعی تولیدی با سیاست‌های پیچیده رقابت‌پذیر می‌ماند در حالی که فاصله قابل‌توجهی تا بهینه Belady باقی است. **این تنظیمات اساساً با تنظیمات ما متفاوت‌اند:** مدخل‌های KV و پیشوندها از متن منبع قابل محاسبه مجددند، پس خطا تأخیر هزینه دارد نه اطلاعات. خاطرات ایجنت رکوردهای معنایی‌اند که پس از حذف، منبعشان دیگر در دسترس نیست.

۲.۴ الگوریتم‌های آنلاین و تحلیل رقابتی

[1] Belady ثابت کرد که حذف صفحه‌ای که دورتر از همه در آینده درخواست می‌شود، برای صفحه‌بندی بهینه است. Sleator و [2] Tarjan تحلیل رقابتی را معرفی کردند و نشان دادند LRU k-رقابتی است. گونه‌های وزن‌دار و آگاه از اندازه به [3] GreedyDual و [4] GreedyDual-Size و الگوریتم‌های تصادفی $O(\log k)$-رقابتی برای صفحه‌بندی وزن‌دار [5] انجامیدند. کوله‌پشتی آنلاین تصادفی [6] *پذیرش* برگشت‌ناپذیر آیتم‌هایی با اندازه و ارزش تصادفی را مطالعه می‌کند.

نزدیک‌ترین مدل کلاسیک، **مسئله کوله‌پشتی آنلاین با امکان حذف** (removable online knapsack) از Iwama و Taketomi [25] است: آیتم‌ها به‌صورت آنلاین می‌رسند، هر یک باید هنگام ورود پذیرفته یا رد شود، و آیتم‌های پذیرفته‌شده بعداً می‌توانند، به‌طور برگشت‌ناپذیر، برای باز کردن جا کنار گذاشته شوند. این دقیقاً ساختار *امکان‌پذیری* AMEP است. تفاوت دو مسئله در *تابع هدف* است. در کوله‌پشتی با امکان حذف، سود برابر ارزش مجموعه‌ای است که در پایان نگه داشته شده، پس فقط محتوای نهایی مهم است. در AMEP، مطلوبیت *در طول زمان* و با هر درخواست برای آیتمی که نگه داشته شده جمع می‌شود؛ پس ارزش یک آیتم به این بستگی دارد که *کی* و *چند بار* لازم می‌شود، و نگه‌داشتن آیتم در ابتدا می‌تواند ارزشمند باشد حتی اگر بعداً کنار گذاشته شود. همین هدف زمانی است که آمار درخواست (نرخ، تازگی) را مرتبط می‌کند و AMEP را به کش پیوند می‌دهد نه به بسته‌بندی.

الگوریتم‌های همراه با پیش‌بینی. خط پژوهشی اخیر با دادن پیش‌بینی‌های (احتمالاً نادرست) به الگوریتم‌های آنلاین، کران‌های پایین بدترین حالت را دور می‌زند و عملکرد را با *سازگاری* (با پیش‌بینی کامل)، *مقاومت* (با پیش‌بینی دلخواه) و *هم‌واری* (افت با خطای پیش‌بینی) می‌سنجد. برای کش، Lykouris و Vassilvitskii [26] نشان دادند که پیش‌بینی زمان درخواست بعدی به الگوریتمی می‌انجامد که با پیش‌بینی خوب تقریباً بهینه و با پیش‌بینی بد $O(\log k)$-رقابتی است؛ همچنین [27] را ببینید. در حافظه ایجنت، امتیاز اهمیت تعیین‌شده توسط LLM دقیقاً چنین پیش‌بینی‌ای است. تحلیل ما AMEP را در این چارچوب قرار می‌دهد و تفاوتی بنیادین با کش را آشکار می‌کند: تحت حذف برگشت‌ناپذیر، هیچ ضمانت مقاومتی ممکن نیست (قضیه ۲)، پس همه ضمانت‌ها باید از سازگاری و هم‌واری بیایند (نتیجه ۱).

بنابراین AMEP برگشت‌ناپذیری کوله‌پشتی با امکان حذف را با پاداش‌های مبتنی بر درخواستِ کش ترکیب می‌کند. تا جایی که می‌دانیم این ترکیب تحلیل نشده است، و نتایج ما نشان می‌دهد رفتاری متفاوت با هر دو مسئله والد دارد.

---

۳. صورت‌بندی مسئله

۳.۱ تنظیمات

زمان گسسته است، $t = 1, \dots, T$، با یک رویداد در هر گام. هر رویداد یا **ورود** یک آیتم حافظه جدید است یا **درخواست** برای آیتمی که قبلاً وارد شده. آیتم i در زمان a_i با اندازه $s_i > 0$ (توکن) و ارزش $v_i > 0$ (مطلوبیتی که هر بار بازیابی موفق آن حاصل می‌شود) وارد می‌شود. سیاست‌ها s_i را هنگام ورود و تخمین نویزی $\hat{v}_i$ از v_i را (مثلاً امتیاز اهمیت تعیین‌شده توسط LLM) مشاهده می‌کنند؛ رویدادهای آینده را نمی‌بینند. A_t مجموعه آیتم‌هایی است که تا زمان t وارد شده‌اند.

سیاست حافظه $M_t \subseteq A_t$ را با قید ظرفیت $\sum_{i \in M_t} s_i \le B$ نگه می‌دارد. وقتی آیتم j وارد می‌شود، درج می‌شود و سپس سیاست آیتم‌هایی را (احتمالاً خود j) حذف می‌کند تا قید برقرار شود. **حذف برگشت‌ناپذیر است:**

$$M_t \subseteq M_{t-1} \cup \{j_t\},$$

که در آن j_t آیتمی است که در t وارد می‌شود (در صورت وجود). درخواست برای آیتم i در زمان t پاداش v_i می‌دهد اگر $i \in M_t$ و در غیر این صورت 0.

۳.۲ تابع هدف

سیاست π مطلوبیت کل خود را بیشینه می‌کند:

$$U(\pi) = \sum_{t:\, e_t = \mathrm{req}(i)} v_i \cdot \mathbf{1}[i \in M_t^{\pi}].$$

هر سیاست را با **نسبت مطلوبیت** $U(\pi)/U(\mathrm{OPT})$ می‌سنجیم که در آن OPT بهینه آفلاین پیش‌آگاه است که کل دنباله رویدادها را از پیش می‌داند. در تحلیل تصادفی، با $\mathrm{OPT}_{\mathrm{on}}$ نیز مقایسه می‌کنیم: بهترین سیاستی که درخواست‌های آینده را پیش‌بینی نمی‌کند.

> **تعریف ۱ (AMEP).** با ظرفیت B و دنباله‌ای آنلاین از ورودها $(a_i, s_i, \hat{v}_i)$ و درخواست‌ها، حافظه‌های $M_1, M_2, \dots$ را با $\sum_{i \in M_t} s_i \le B$ و $M_t \subseteq M_{t-1} \cup \{j_t\}$ برای همه t چنان انتخاب کن که $U(\pi)$ بیشینه شود.

۳.۳ تفاوت AMEP با کش کلاسیک

ویژگی	کش کلاسیک	حافظه ایجنت (AMEP)
حذف	برگشت‌پذیر (بازیابی مجدد هنگام خطا)	**برگشت‌ناپذیر** (مگر دوباره مشاهده شود)
اندازه آیتم	یکسان (صفحه)	متغیر (توکن)
ارزش آیتم	هزینه خطای یکسان	ناهمگن؛ برخی آیتم‌ها نادر اما حیاتی‌اند
نگهداری جزئی	ندارد	دارد — **فشرده‌سازی/خلاصه‌سازی**
بازیابی	برخورد/خطای دقیق	نویزی، با بزرگ شدن حافظه افت می‌کند (کار آینده)

سطر اول تعیین‌کننده است. در صفحه‌بندی، حذف اشتباه هزینه یک بار آوردن مجدد را دارد؛ در AMEP *تمام* ارزش آینده آیتم را از بین می‌برد. این تغییر می‌دهد که کدام تصمیم‌ها بهینه‌اند (گزاره ۱) و مسئله آنلاین چقدر دشوار است (قضیه‌های ۲ و ۳).

۳.۴ مدل‌های بار کاری

درخواست‌ها از **مدل دسترسی مجدد مستقل (IRM)** با محبوبیت متغیر با زمان پیروی می‌کنند: در گام درخواست t، آیتم $i \in A_t$ با احتمال $w_i(t) / \sum_{j \in A_t} w_j(t)$ درخواست می‌شود. بارهای کاری در تعریف $w_i(t)$ تفاوت دارند:

- **IRM (ایستا):** $w_i(t) = \lambda_i$، با λ_i دم‌سنگین (Pareto).

- **محلیت زمانی:** $w_i(t) = \lambda_i \exp(-(t - a_i)/\tau)$؛ آیتم‌های تازه‌تر محبوب‌ترند.
- **نادر-حیاتی:** ایستا، اما کسری از آیتم‌ها *حیاتی*‌اند: ارزش بالا، محبوبیت پایین (حساسیت‌ها، اطلاعات ورود، ضرب‌الاجل‌ها).
- **رانش:** هر آیتم به یک موضوع تعلق دارد؛ محبوبیت موضوع‌ها در مرز رژیم‌ها از نو نمونه‌گیری می‌شود (تغییر علایق کاربر).
- **دستیار ترکیبی:** ترکیبی از آیتم‌های گذرا (با زوال سریع و محبوب)، پایدار (ایستا) و حیاتی.

برای گزاره‌های بدترین حالت، دنباله‌های **خصمانه** را نیز در نظر می‌گیریم.

---

۴. تحلیل نظری

همه اثبات‌ها به پیوست الف موکول شده‌اند.

۴.۱ بهینه آفلاین

نخستین نامزد طبیعی برای سیاست مرجع، قاعده Belady است. این قاعده شکست می‌خورد.

> **گزاره ۱ (شکست Belady تحت برگشت‌ناپذیری).** حتی با اندازه‌ها و ارزش‌های واحد، قاعده حذف «دورترین در آینده» می‌تواند به کسر $1/L$ از بهینه برسد، برای هر $L \geq 1$.

شهود. قاعده Belady برای صفحه‌بندی بهینه است زیرا صفحه حذف‌شده را می‌توان بعداً بازگرداند؛ فقط باید خطای بعدی را به تعویق بیندازد. تحت برگشت‌ناپذیری، پرسش درست این نیست که آیتم کی دوباره لازم می‌شود، بلکه این است که چه *مقدار* ارزش آینده در کل دارد. آیتمی که به‌زودی اما فقط یک بار درخواست می‌شود، باید پیش از آیتمی که دیرتر اما بارها درخواست می‌شود قربانی شود.

چون حذف برگشت‌ناپذیر است، هر زمان‌بندی هر آیتم را در بازه‌ای پیوسته که از زمان ورودش آغاز می‌شود نگه می‌دارد. این ساختار بازه‌ای، صورت‌بندی دقیقی را که اوراکل ما استفاده می‌کند به دست می‌دهد.

> **قضیه ۱ (پیچیدگی AMEP آفلاین).** (الف) AMEP آفلاین NP-سخت است، حتی وقتی هر آیتم دقیقاً یک بار درخواست شود. (ب) اگر همه اندازه‌ها برابر باشند، AMEP آفلاین با ارزش‌های دلخواه با کاهش به جریان کمینه‌هزینه در زمان چندجمله‌ای حل‌پذیر است.

اوراکل دقیق. فرض کنید $r_{i,1} < \cdots < r_{i,K_i}$ زمان‌های درخواست آیتم i باشند و $y_{i,k} \in \{0,1\}$ نشان دهد که در درخواست k-ام هنوز نگه داشته شده است. آنگاه

$$\max \sum_{i,k} v_i \, y_{i,k} \quad \text{s.t.} \quad y_{i,k} \leq y_{i,k-1}, \qquad \sum_{i} s_i \, y_{i,\nu_i(t)} \leq B \;\; \forall t \in \mathcal{A},$$

که در آن $\mathcal{A}$ مجموعه زمان‌های ورود و $\nu_i(t)$ اندیس نخستین درخواست i پس از t است. بار حافظه فقط در زمان ورودها می‌تواند افزایش یابد، پس این قیدها کافی‌اند؛ آیتم‌های بدون درخواست آینده بدون هزینه کنار گذاشته می‌شوند. این ILP را با HiGHS حل می‌کنیم؛ آرام‌سازی LP کران بالا می‌دهد.

۴.۲ کران‌های پایین برای سیاست‌های آنلاین

> **قضیه ۲ (هیچ سیاست آنلاین رقابتی وجود ندارد).** برای هر سیاست آنلاین، قطعی یا تصادفی، هر $B \geq 1$ و هر $n > B$، نمونه‌ای با اندازه‌ها و ارزش‌های واحد وجود دارد که مطلوبیت مورد انتظار سیاست روی آن حداکثر $(B/n) \cdot U(\mathrm{OPT})$ است. بنابراین هیچ سیاست آنلاینی برای AMEP نسبت رقابتی کراندار ندارد.

شهود. پس از ورود n آیتم غیرقابل‌تمایز، هر سیاست حداکثر B تا از آن‌ها را می‌تواند نگه دارد. سپس دشمن مکرراً یکی از فراموش‌شده‌ها را درخواست می‌کند. در صفحه‌بندی، سیاست با آوردن مجدد آن جبران می‌کرد؛ تحت برگشت‌ناپذیری نمی‌تواند. **بنابراین تحلیل رقابتی بدترین حالت برای حافظه ایجنت بی‌اطلاع‌کننده است**، و این انگیزه تحلیل توزیعی و استفاده از سیگنال‌های ارزش است.

نتیجه بعدی نشان می‌دهد که سیگنال‌های ارزش نه‌تنها مفید، بلکه ضروری‌اند، حتی وقتی درخواست‌ها ملایم‌اند.

> **تعریف ۲.** سیاستی **بی‌توجه به ارزش** است اگر تصمیم‌هایش فقط به زمان ورود، اندازه و تاریخچه دسترسی بستگی داشته باشد، نه به $\hat{v}_i$. Random، FIFO، LFU، LRU و منحنی‌های فراموشی به سبک ابینگهاوس بی‌توجه به ارزش‌اند.
>
> **قضیه ۳ (شکست سیاست‌های بی‌توجه به ارزش تحت IRM).** برای هر سیاست بی‌توجه به ارزش، هر B، هر $n > B$ و هر $\varepsilon > 0$، نمونه IRM ایستایی با اندازه‌های واحد وجود دارد که مطلوبیت مورد انتظار سیاست روی آن حداکثر $(B/n + \varepsilon)$ برابر مطلوبیت سیاست شاخص ارزش–نرخ–اندازه بخش ۴.۳ است.

شهود. اگر n آیتم جز در ارزش از نظر آماری یکسان به نظر برسند، سیاستی که ارزش را نادیده می‌گیرد، تنها آیتم حیاتی را با احتمال حداکثر B/n نگه می‌دارد. فراموشی مبتنی بر تازگی دقیقاً چنین سیاستی است، که شکست‌های واقعیت‌های حیاتی مشاهده‌شده در عمل [20] و در بخش ۷.۳ را توضیح می‌دهد.

۴.۳ حالت تصادفی: یک سیاست شاخص‌محور

IRM ایستا، $w_i(t) = w_i$، را در نظر بگیرید و **شاخص ارزش–نرخ–اندازه** را تعریف کنید:

$$\phi_i = \frac{w_i \, v_i}{s_i},$$

یعنی مطلوبیت مورد انتظار به ازای هر واحد حافظه در هر درخواست. سیاست **DENSITY** در هر زمان، طولانی‌ترین پیشوند A_t مرتب‌شده به ترتیب نزولی ϕ_i را که اندازه کلش در B جا می‌شود نگه می‌دارد.

قضیه ۴ (سیاست شاخص‌محور تقریباً بهینه است و برگشت‌ناپذیری رایگان است). تحت IRM ایستا با (w_i, v_i, s_i) معلوم: (۱) DENSITY به‌صورت برگشت‌ناپذیر قابل‌پیاده‌سازی است، یعنی آیتمی که حذف می‌کند هرگز دوباره انتخاب نمی‌شد؛ (۲) برای هر سیاست π که درخواست‌های آینده را پیش‌بینی نمی‌کند (حتی اگر همه ورودهای آینده را بداند)،

$$\mathbb{E}[U(\text{DENSITY})] \;\geq\; \left(1 - \frac{s_{\max}}{B}\right) \mathbb{E}[U(\pi)].$$

شهود. در هر گام درخواست، پاداش مورد انتظار هر حافظه با یک کوله‌پشتی کسری روی آیتم‌های واردشده کران‌دار می‌شود. پیشوند DENSITY بخش صحیح جواب حریصانه کسری است و حداکثر به اندازه ظرفیت یک آیتم ضرر می‌کند. چون ورودهای جدید فقط آستانه حریصانه را بالا می‌برند، آیتمی که زیر آن قرار گرفت هرگز دوباره بالای آن نمی‌رود، پس ناتوانی در بازگرداندن آیتم‌های حذف‌شده هزینه‌ای ندارد. برای حافظه ایجنت، $s_{\max}/B$ کوچک است (یک خاطره چند صد توکن است؛ بودجه‌ها ده‌ها هزار توکن)، پس ضمانت نزدیک به ۱ است.

نتیجه ۱ (ضمانت همراه با پیش‌بینی). فرض کنید DENSITY از شاخص‌های پیش‌بینی‌شده $\hat{\phi}_i$ (مثلاً از امتیاز اهمیت LLM) استفاده کند که هنگام ورود ثابت می‌شوند و خطای ضربی $\hat{\phi}_i/\phi_i \in [1-\delta, 1+\delta]$ دارند. آنگاه همچنان به‌صورت برگشت‌ناپذیر قابل‌پیاده‌سازی است و

$$\mathbb{E}[U] \;\geq\; \frac{1-\delta}{1+\delta}\left(1 - \frac{s_{\max}}{B}\right) \mathbb{E}[U(\pi)].$$

در اصطلاحات الگوریتم‌های همراه با پیش‌بینی [26, 27]، این سیاست $(1 - s_{\max}/B)$-**سازگار** و **هموار** است: ضمانتش با خطای پیش‌بینی δ به‌طور پیوسته افت می‌کند. قضیه ۲ نشان می‌دهد هیچ سیاستی نمی‌تواند افزون بر این در برابر پیش‌بینی‌های دلخواه **مقاوم** باشد. برخلاف صفحه‌بندی، که در آن سیاست مبتنی بر پیش‌بینی می‌تواند به LRU بازگردد و ضمانت $O(\log k)$ را حفظ کند، حذف برگشت‌ناپذیری که بر اساس پیش‌بینی بد انجام شده قابل جبران نیست. *بنابراین برای حافظه ایجنت، کیفیت پیش‌بینی‌کننده ارزش یکی از عوامل متعدد نیست: تنها منبع ضمانت است.*

۴.۴ بهای پیش‌آگاهی

معیار تجربی ما، OPT پیش‌آگاه، همه درخواست‌های آینده را می‌داند. چه مقدار از فاصله یک سیاست آنلاین تا OPT *اجتناب‌ناپذیر* است، چون آینده ناشناخته است، و نه به دلیل سیاست نابهینه؟ نتیجه بعدی برای بارهای کاری ایستا به این پرسش پاسخ می‌دهد.

قضیه ۵ (بهای پیش‌آگاهی). IRM ایستا با n آیتم که پیش از H درخواست حاضرند، اندازه‌ها و ارزش‌های واحد و احتمال‌های درخواست $p_i \le p$ را در نظر بگیرید. آنگاه DENSITY یک سیاست آنلاین بهینه است، و: (الف) **کران بالا.** $\frac{\mathbb{E}[U(\mathrm{OPT})]}{\mathbb{E}[U(\mathrm{DENSITY})]} \le 1 + \frac{B}{D}\left(\sqrt{2Hp\ln(n+1)} + \frac{1}{3}\ln(n+1)\right)$، که در آن $D = H\sum_{i\in \text{top-}B} p_i$ مطلوبیت مورد انتظار DENSITY است. برای محبوبیت یکنواخت این برابر $1 + \sqrt{2n\ln(n+1)/H} + n\ln(n+1)/(3H)$ است که وقتی هر آیتم $\omega(\log n)$ بار درخواست شود به ۱ میل می‌کند. (ب) **کران پایین.** برای محبوبیت یکنواخت، $B = 1$ و $H = n$، این نسبت برابر $(1 + o(1))\ln n / \ln\ln n$ است.

شهود. وقتی درخواست‌ها پراکنده‌اند، شانس به‌تنهایی چند آیتم را در نگاه به گذشته بسیار محبوب‌تر از انتظار می‌کند؛ OPT پیش‌آگاه از این شانس بهره می‌برد و هیچ سیاست آنلاینی نمی‌تواند. این فاصله یک اثر «توپ‌ها در سطل‌ها» است و فقط وقتی هر آیتم بارها درخواست شود از بین می‌رود. در حافظه ایجنت، بیشتر آیتم‌ها به‌ندرت یا هرگز درخواست نمی‌شوند (در بارهای کاری ما به‌طور میانگین حدود ۲٫۳ درخواست برای هر آیتم)، پس **بخش قابل‌توجهی از فاصله هر سیاست تا OPT ماهیت اطلاعاتی دارد، نه الگوریتمی.** این تفکیک را در بخش ۷.۲ با DENSITY* به‌طور تجربی می‌سنجیم: مرجعی ممتاز که محبوبیت و ارزش واقعی هر آیتم را می‌داند.

۴.۵ توسعه: فشرده‌سازی به‌عنوان حذف جزئی

خلاصه‌سازی گزینه سومی بین نگه‌داشتن و فراموش کردن ارائه می‌دهد: آیتمی با اندازه s_i و ارزش v_i با خلاصه‌ای به اندازه ρs_i که ارزش γv_i را حفظ می‌کند جایگزین می‌شود، با $\rho < \gamma \le 1$. فشرده‌سازی چگالی آیتم را با ضریب γ/ρ افزایش می‌دهد و همتای صحیح پرکردن کسری در کران کوله‌پشتی قضیه ۴ است: فشرده کردن آیتم حاشیه‌ای به‌جای حذف آن، بخشی از اتلاف صحیح‌بودن $s_{\max}/B$ را جبران می‌کند و مهم‌تر، ردی از هر آیتمی که در غیر این صورت برای همیشه از دست می‌رفت نگه می‌دارد. این AMEP را به دیدگاه نرخ–اعوجاج فشرده‌سازی حافظه [17] پیوند می‌دهد. فشرده‌سازی را در بخش ۷.۶ به‌طور تجربی ارزیابی می‌کنیم.

---

۵. سیاست پیشنهادی: VRS

DENSITY محبوبیت معلوم و ایستایی را فرض می‌کند. **VRS (حذف ارزش–نرخ–اندازه)** نمونه عملی آن است: آیتمی با کوچک‌ترین شاخص تخمینی $\hat{\phi}_i = \hat{\lambda}_i \hat{v}_i / s_i$ را حذف می‌کند.

الگوریتم ۱: VRS

```
Input: capacity B, value estimates v̂, prior strength b0, half-life h
State: discounted access count c_i and last-update time for each held item

On arrival of item j at time t:
    insert j;  c_j ← 0
    while Σ_{i∈M} s_i > B:
        evict argmin_{i∈M}  λ̂_i(t) · v̂_i / s_i        # or compress it (VRS+C)
On request for item i at time t:
    if i ∈ M:  c_i ← c_i · 2^{-(t - t_i)/h} + 1      # reward v_i is collected

λ̂_i(t) = (c_i(t) + m(t) · b0) / (E_i(t) + b0)
    E_i(t): discounted exposure since arrival;  m(t): population mean request rate so far
```

تخمین نرخ. $\hat{\lambda}_i$ یک تخمین بیز تجربی است: میانگین پسین با پیشین گاما که نرخ آیتم جدید را با قدرت پیشین b_0 (بر حسب گام) به سمت میانگین جمعیت $m(t)$ منقبض می‌کند، تا آیتم‌های جدید نه بلافاصله حذف شوند و نه برای همیشه محافظت شوند. نیمه‌عمر h دسترسی‌های قدیمی را کم‌وزن می‌کند و VRS را با محلیت زمانی و رانش سازگار می‌سازد؛ تخمین‌گر ایستای قضیه ۴ را بازمی‌گرداند.

تخمین ارزش. در استقرار، $\hat{v}_i$ می‌تواند از امتیاز اهمیت LLM (مانند Generative Agents)، نوع آیتم (مثلاً واقعیت‌های مرتبط با ایمنی، اطلاعات ورود، تعهدات) یا سیگنال‌های صریح کاربر بیاید. نتیجه ۱ و بخش ۷.۵ اثر نویز تخمین را می‌سنجند.

پیچیدگی. با صف اولویت روی $\hat{\phi}_i$ و به‌روزرسانی تنبل، هر عملیات $O(\log |M|)$ هزینه دارد. پیاده‌سازی مرجع ما حافظه را پیمایش می‌کند و برای هر حذف $O(|M|)$ هزینه دارد، که در پایتون همچنان تنها حدود ۱۶۰ میکروثانیه برای هر رویداد است (بخش ۷.۱).

گونه فشرده‌ساز (VRS+C). نخستین باری که آیتمی برای حذف انتخاب می‌شود، فشرده می‌شود ($\rho = 0.25$، $\gamma = 0.6$)؛ آیتم فشرده‌شده‌ای که دوباره انتخاب شود حذف می‌شود.

---

۶. MemSim: چارچوب شبیه‌سازی

۶.۱ طراحی

MemSim یک بسته پایتونی حدوداً ۱٬۵۰۰ خطی با پنج جزء است.

- **بارهای کاری** (`workloads.py`): مولدهای پنج مدل بخش ۳.۴، پارامتری بر حسب افق، نرخ ورود، توزیع‌های اندازه/ارزش/محبوبیت، نویز تخمین ارزش، مقیاس زمانی تازگی، ترکیب آیتم‌های حیاتی و سرعت رانش.
- **سیاست‌ها** (`policies.py`): رابطی مشترک (`on_insert`، `on_access`، `decide`) و دوازده سیاست، به‌علاوه پوششی که به هر سیاست فشرده‌سازی اضافه می‌کند.
- **شبیه‌ساز** (`simulator.py`): موتوری رویدادمحور که ظرفیت و برگشت‌ناپذیری را اعمال و مطلوبیت، نرخ برخورد، یادآوری واقعیت‌های حیاتی و زمان اجرا را ثبت می‌کند.

- **اوراکل** (`oracle.py`): ILP بخش ۴.۱ که با HiGHS از طریق SciPy حل می‌شود، همراه با کران‌های بالای آرام‌سازی LP.
- **داده واقعی** (`locomo.py`، `llm.py`): مکالمات LoCoMo [28] را به ردهای AMEP تبدیل می‌کند و پیش‌بینی‌های آنلاین اهمیت را از هر نقطه پایانی LLM سازگار با OpenAI دریافت می‌کند، با کش روی دیسک تا نتایج بدون دسترسی به API تکرارپذیر باشند.

درستی‌سنجی. مجموعه آزمونی بررسی می‌کند که اوراکل ILP روی ۶۰ نمونه کوچک تصادفی با شمارش کامل منطبق است و هیچ سیاست آنلاینی در هیچ بار کاری از اوراکل بهتر عمل نمی‌کند.

۶.۲ روش‌های مبنا

سیاست	توضیح	منبع
Random	حذف تصادفی یکنواخت	—
FIFO	حذف قدیمی‌ترین آیتم	—
LRU	حذف آیتمی با کمترین استفاده اخیر	کلاسیک
LFU	حذف آیتمی با کمترین تکرار استفاده	کلاسیک
GDS	GreedyDual-Size با هزینه $\hat{v}_i$	Cao & Irani [4]
Ebbinghaus	ماندگاری $e^{-\Delta t/S}$، قدرت S با یادآوری رشد می‌کند	MemoryBank [9]
GenAgents	تازگی $\delta^{\Delta t}$ + اهمیت نرمال‌شده	Park et al. [7]
ImpDecay	منحنی فراموشی وزن‌دار با اهمیت	الهام‌گرفته از FadeMem [13]
VRS (ما)	شاخص ارزش–نرخ–اندازه	بخش ۵
VRS+C (ما)	با فشرده‌سازی VRS	بخش ۵
DENSITY*	سیاست شاخص‌محور با محبوبیت و ارزش *واقعی* (ممتاز؛ غیرقابل استقرار)	قضیه ۴
OPT	بهینه آفلاین پیش‌آگاه (ILP)	بخش ۴.۱

امتیازهای بازیابی مبتنی بر ارتباط (مانند Generative Agents) به پرسش جاری بستگی دارند و در زمان حذف تعریف‌نشده‌اند؛ بنابراین جمله‌های تازگی و اهمیت را حفظ می‌کنیم. ImpDecay از FadeMem الهام گرفته و بازپیاده‌سازی آن نیست.

۶.۳ معیارها

- **نسبت مطلوبیت:** $U(\pi)/U(\mathrm{OPT})$، معیار اصلی.
- **یادآوری واقعیت‌های حیاتی:** کسری از درخواست‌های آیتم‌های حیاتی که پاسخ داده می‌شوند.
- **نرخ برخورد:** کسر بدون وزن درخواست‌هایی که پاسخ داده می‌شوند.
- **زمان اجرا:** میکروثانیه زمان واقعی برای هر رویداد.

---

۷. آزمایش‌ها

۷.۱ تنظیمات آزمایش

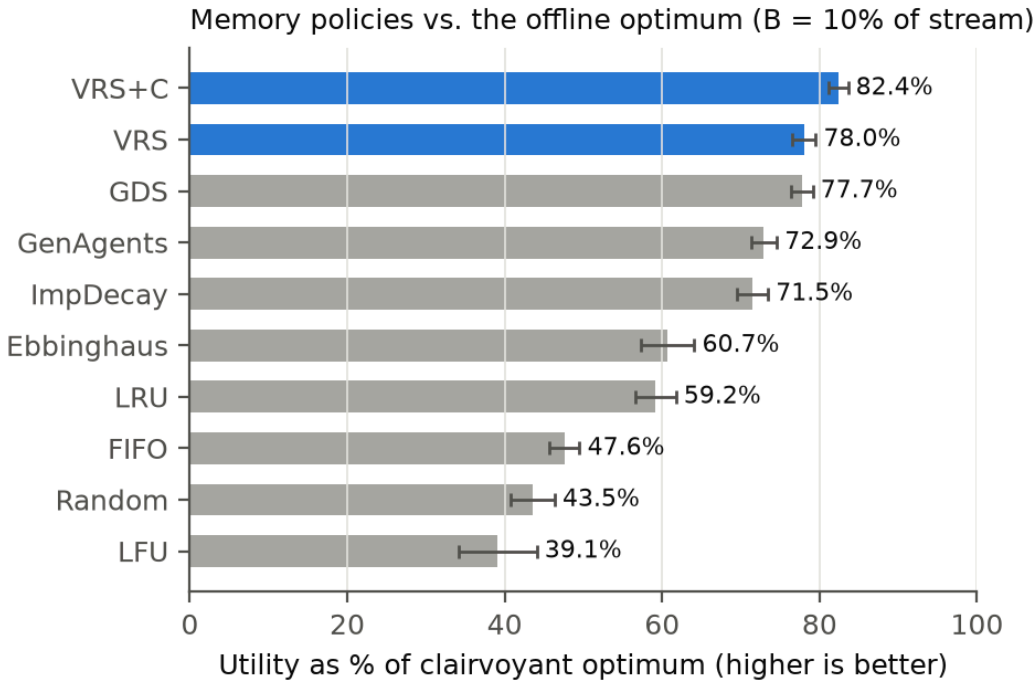
بارهای کاری. هر رد $T = 3000$ رویداد با احتمال ورود 0.3 در هر گام دارد (حدود ۹۰۰ آیتم و ۲۱۰۰ درخواست). اندازه‌ها لگ‌نرمال با میانه ۵۰ توکن‌اند ($\mu = 0$، $\sigma = 1$)؛ ارزش‌ها لگ‌نرمال‌اند ($\sigma = 0.6$، محدود به $[8, 400]$)؛ محبوبیت پایه Pareto با شکل ۱٫۵ است. تخمین‌های ارزش $\hat{v}_i = v_i \cdot e^{\epsilon_i}$ با $\epsilon_i \sim \mathcal{N}(0, 0.5^2)$ هستند. بارهای کاری زمانی از $\tau = 150$ گام استفاده می‌کنند. آیتم‌های حیاتی (۵ درصد) ارزش ۳۰ برابر و محبوبیت ۰٫۱۵ برابر دارند. بار کاری ترکیبی شامل ۵ درصد آیتم حیاتی، ۲۵ درصد پایدار و ۷۰ درصد گذرا ($\tau = 75$، محبوبیت ۳ برابر) است. بار کاری رانش ۱۰ موضوع دارد که محبوبیت Dirichlet(0.5) آن‌ها در ۵ رژیم از نو نمونه‌گیری می‌شود.

بودجه‌ها و بذرها. بودجه حافظه B برابر ۲٫۵، ۵، ۱۰، ۲۰ یا ۴۰ درصد اندازه کل جریان تنظیم می‌شود؛ ۱۰ درصد پیش‌فرض است. همه نتایج روی **۱۰ بذر آزمون** (۰ تا ۹) میانگین‌گیری شده‌اند. ابرپارامترهای همه سیاست‌های قابل‌تنظیم (VRS، ImpDecay، GenAgents، Ebbinghaus) با جستجوی شبکه‌ای روی **۵ بذر اعتبارسنجی مجزا** (۱۰۰۰ تا ۱۰۰۴) در بودجه پیش‌فرض و با بیشینه‌سازی میانگین نسبت مطلوبیت در همه بارهای کاری انتخاب شده‌اند (پیوست ه).

اوراکل. همه ۲۵۰ نمونه اصلی با شکاف نسبی MIP حداکثر ۰٫۶۵ درصد (میانگین ۰٫۰۷ درصد) حل شده‌اند، پس نسبت‌های مطلوبیت گزارش‌شده تا این حد دقیق‌اند.

سخت‌افزار. ۲۸ Intel Core i7-14700HX، هسته منطقی، ۳۲ گیگابایت RAM؛ SciPy 1.18 (HiGHS)، Python 3.12. کل خط لوله اصلی حدود ۲۳ دقیقه با ۲۴ پردازه کارگر اجرا می‌شود.

RQ1 ۷.۲ — روش‌های ابتکاری موجود چقدر از بهینه فاصله دارند؟



شکل ۱. مطلوبیت به‌صورت درصدی از بهینه پیش‌آگاه در $B = 10\%$، میانگین روی پنج بار کاری (میله‌های خطا: بازه اطمینان ۹۵ درصد روی ۱۰ بذر).

جدول ۱. مطلوبیت به‌صورت درصد OPT در $B = 10\%$ (میانگین ± انحراف معیار روی ۱۰ بذر؛ بهترین هر ستون پررنگ).

سیاست	IRM (ایستا)	محلیت زمانی	نادر-حیاتی	رانش	دستیار ترکیبی	میانگین
Random	36.9 ± 5.7	71.5 ± 3.8	35.0 ± 8.1	36.7 ± 5.3	37.5 ± 7.9	43.5 ± 4.5
FIFO	37.0 ± 3.8	88.2 ± 0.9	36.6 ± 5.9	35.7 ± 3.2	40.2 ± 6.2	47.6 ± 3.1
LRU	49.9 ± 6.3	90.1 ± 1.9	50.9 ± 6.7	48.6 ± 6.2	56.3 ± 9.6	59.2 ± 4.2
LFU	48.0 ± 7.6	19.7 ± 6.2	49.1 ± 8.7	44.0 ± 9.1	34.9 ± 16.5	39.1 ± 8.0
GDS	72.1 ± 3.4	**90.6 ± 1.3**	74.2 ± 5.8	68.3 ± 2.8	**83.3 ± 5.7**	77.7 ± 2.3
Ebbinghaus	56.2 ± 6.9	82.4 ± 3.2	55.0 ± 9.0	51.1 ± 7.9	58.7 ± 9.9	60.7 ± 5.5
GenAgents	64.1 ± 4.1	90.6 ± 1.2	67.7 ± 6.8	61.8 ± 4.5	80.6 ± 5.5	72.9 ± 2.6
ImpDecay	68.2 ± 4.9	79.0 ± 2.4	70.4 ± 4.7	64.0 ± 4.2	75.9 ± 7.9	71.5 ± 3.1
VRS	**76.8 ± 3.9**	78.5 ± 1.7	**78.6 ± 4.9**	**73.8 ± 4.2**	82.4 ± 4.9	78.0 ± 2.4

چهار یافته برجسته است.

(۱) جای پیشرفت قابل‌توجهی باقی است. بهترین روش ابتکاری موجود، GDS، به‌طور میانگین به ۷۷٫۷ درصد بهینه پیش‌آگاه می‌رسد و در $B = 10\%$، ۲۲ درصد از مطلوبیت قابل‌دستیابی را بلااستفاده می‌گذارد. سیاست‌های مبتنی بر تازگی و تکرار که در عمل غالب‌اند تنها به ۳۹ تا ۶۱ درصد می‌رسند.

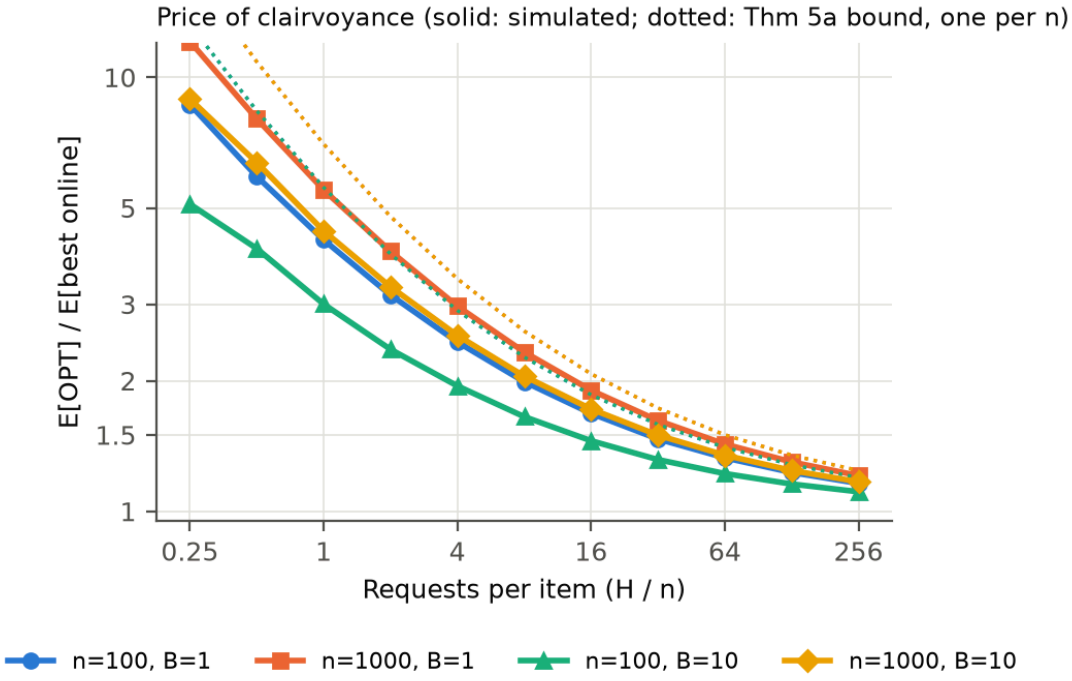
(۲) آگاهی از ارزش عامل غالب است. هر سیاست آگاه از ارزش (VRS، ImpDecay، GenAgents، GDS) به‌طور میانگین از هر سیاست بی‌توجه به ارزش (Random، Ebbinghaus، FIFO، LFU، LRU) بهتر عمل می‌کند، همان‌طور که قضیه ۳ پیش‌بینی می‌کند. تغییری یک‌خطی از LRU به GDS، ۱۸٫۶ واحد اضافه می‌کند (آزمون رتبه‌علامت‌دار Wilcoxon جفتی روی ۵۰ جفت بار کاری–بذر، $p < 10^{-12}$).

(۳) VRS قوی‌ترین قاعده حذف است، آنجا که مدلش صدق می‌کند. VRS در بارهای کاری IRM، نادر-حیاتی و رانش بهترین سیاست است؛ GDS را ۴٫۳ تا ۵٫۵ واحد شکست می‌دهد و در هر سه، روی همه ۱۰ بذر برنده است ($p = 0.002$ برای هر بار کاری). در بار کاری ترکیبی از نظر آماری با GDS برابر است (-0.9 واحد، $p = 0.08$) اما در بار کاری محلیت زمانی عقب است (۷۸٫۵ در برابر ۹۰٫۶ درصد). در آنجا محبوبیت هر آیتم از زمان ورودش زوال می‌یابد، پس تازگی خود سیگنالی تقریباً بهینه است؛ این با تحلیل [23] منطبق است که نشان می‌دهد LRU وقتی مفید بودن با سن به‌صورت نمایی زوال یابد تقریباً بهینه است. با میانگین روی بارهای کاری در $B = 10\%$، VRS و GDS از نظر آماری قابل‌تمایز نیستند (۷۸٫۰ در برابر ۷۷٫۷ درصد، $p = 0.22$). روی همه بودجه‌ها VRS ۱٫۳ واحد پیش است ($p < 10^{-3}$) و با کنار گذاشتن بار کاری زمانی ۴٫۰ واحد ($p < 10^{-19}$)، برنده در ۷۷ درصد نمونه‌ها).

چه مقدار از فاصله قابل اجتناب است؟ جدول ۴ فاصله هر سیاست تا OPT را با DENSITY *تفکیک می‌کند: سیاست شاخص‌محور قضیه ۴ که محبوبیت و ارزش واقعی هر آیتم را دارد.* ***شکاف اطلاعاتی*** *(DENSITY - OPT)* چیزی است که هیچ سیاست آنلاینی بدون دانستن درخواست‌های آینده نمی‌تواند جبران کند؛ **شکاف تخمین** (DENSITY - *VRS)* *چیزی است که تخمین‌های بهتر نرخ و ارزش می‌توانند جبران کنند. در بارهای کاری ایستا شکاف اطلاعاتی غالب است: ۱۴ تا ۲۶ واحد از OPT، در برابر ۰ تا ۸ واحد شکاف تخمین. در بار کاری رانش، VRS به ۹۹٫۹ درصد DENSITY* می‌رسد، پس عملاً تمام فاصله باقی‌مانده‌اش تا OPT بهای پیش‌آگاهی است. در بارهای کاری زمانی و ترکیبی، که محبوبیت با سن آیتم تغییر می‌کند، شکاف تخمین بزرگ‌تر است (۱۱ تا ۱۷ واحد)، که تخمین بهتر نرخ ناایستا را فرصت الگوریتمی اصلی معرفی می‌کند. شکل ۵ همین پدیده را در تنظیمات قضیه ۵ نشان می‌دهد: با یک درخواست برای هر آیتم، بهینه پس‌نگر ۳ تا ۵٫۵ برابر بهتر از بهترین سیاست آنلاین است، و این نسبت فقط به‌کندی و با متراکم شدن درخواست‌ها به ۱ نزدیک می‌شود. چون خاطرات ایجنت معمولاً به‌ندرت درخواست می‌شوند، **اعداد خام «درصد OPT» نزدیکی سیاست‌های خوب به بهترین عملکرد آنلاین قابل‌دستیابی را کمتر از واقع نشان می‌دهند.**

جدول ۴. تفکیک شکاف در $B = 10\%$ (واحد درصد OPT، میانگین روی ۱۰ بذر).

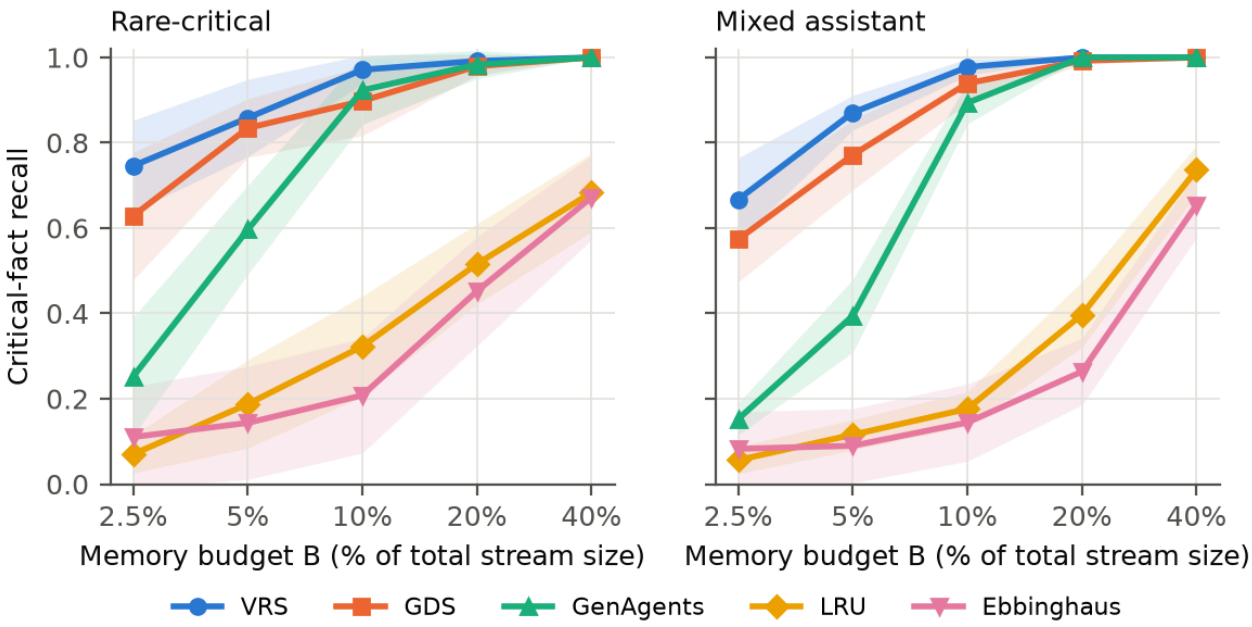
بار کاری	DENSITY*	VRS	GDS	شکاف اطلاعاتی	شکاف تخمین	DENSITY* به‌صورت درصد VRS
IRM (ایستا)	85.1	76.8	72.1	14.9	8.3	90.2
محلیت زمانی	95.7	78.5	90.6	4.3	17.2	82.0
نادر-حیاتی	85.7	78.6	74.2	14.3	7.2	91.6
رانش	73.9	73.8	68.3	26.1	0.1	99.9
دستیار ترکیبی	93.8	82.4	83.3	6.2	11.4	87.8



شکل ۵. بهای پیش‌آگاهی: نسبت بهینه پس‌نگر به بهترین سیاست آنلاین تحت IRM یکنواخت با ورودهای ایستا (خط پیوسته: مونت‌کارلو با ۴٬۰۰۰ تکرار؛ نقطه‌چین: کران بالای قضیه ۵-الف).

(۴) نرخ برخورد معیاری گمراه‌کننده است. LRU نرخ برخورد *بالاتری* از VRS دارد (۵۹٫۵ در برابر ۵۱٫۰ درصد) اما مطلوبیتش ۱۸٫۸ واحد *کمتر* است. گونه حذفی VRS-noValue بالاترین نرخ برخورد را در میان سیاست‌های فقط-حذف دارد (۶۵٫۳ درصد) در حالی که از نظر مطلوبیت نزدیک انتهای رتبه‌بندی است. بیشینه کردن تعداد خاطرات بازیابی‌شده با بیشینه کردن ارزشی که ارائه می‌کنند یکی نیست؛ تمایزی که بنچمارک‌های مبتنی بر recall نمی‌توانند ثبت کنند.

۷.۳ RQ2 — آیا سیاست‌های مبتنی بر تازگی واقعیت‌های حیاتی را فراموش می‌کنند؟

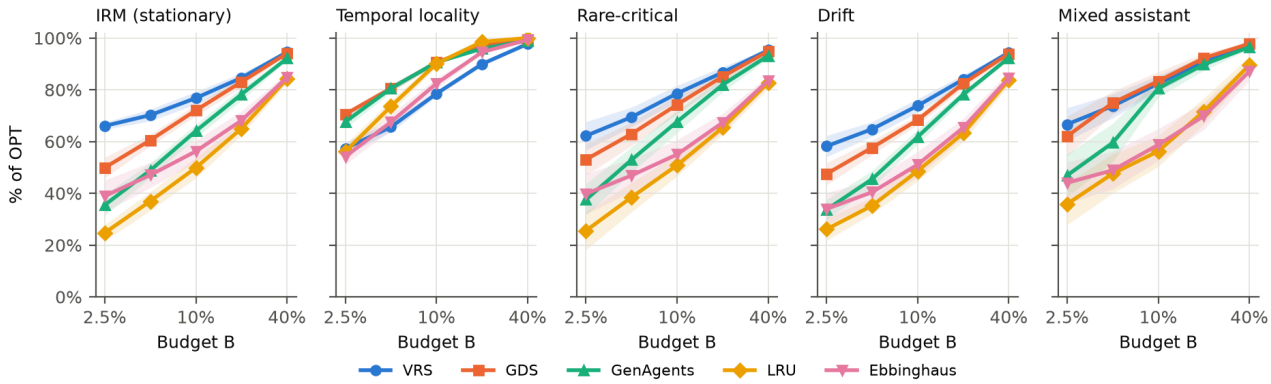


شکل ۲. یادآوری واقعیت‌های حیاتی بر حسب بودجه حافظه در بارهای کاری نادر-حیاتی و ترکیبی.

سیاست‌های بی‌توجه به ارزش به‌طور نظام‌مند مهم‌ترین واقعیت‌ها را فراموش می‌کنند. در $B = 10\%$، LRU تنها به ۱۷٫۶ درصد (ترکیبی) و ۳۲٫۳ درصد (نادر-حیاتی) درخواست‌های واقعیت‌های حیاتی پاسخ می‌دهد و منحنی فراموشی ابینگهاوس تنها به ۱۴٫۴ و ۲۰٫۸ درصد. هر دو *بدتر از حذف تصادفی* عمل می‌کنند (۲۴٫۲ و ۳۳٫۱ درصد). بنابراین منحنی‌های فراموشی نه‌تنها نسبت به ارزش کورند، بلکه فعالانه علیه آیتم‌های نادر سوگیری دارند: آیتمی که به‌ندرت دسترسی می‌شود هرگز قدرت ناشی از یادآوری را که از آن محافظت کند جمع نمی‌کند. VRS ۹۷٫۷ و ۹۷٫۱ درصد و VRS+C ۹۹٫۶ و ۹۹٫۲ درصد واقعیت‌های حیاتی را به یاد می‌آورند.

این شکاف با کمیاب‌تر شدن حافظه بزرگ‌تر می‌شود. در $B = 2.5\%$، VRS همچنان ۶۷ تا ۷۵ درصد و VRS+C ۸۵ تا ۸۶ درصد واقعیت‌های حیاتی را به یاد می‌آورند، در برابر ۵۷ تا ۶۳ درصد برای GDS، ۱۵ تا ۲۵ درصد برای GenAgents و ۶ تا ۱۱ درصد برای LRU و Ebbinghaus. GenAgents شکستی ظریف‌تر را نشان می‌دهد: امتیاز جمعی آن اجازه می‌دهد جمله تازگی بالا بر اهمیت غلبه کند، پس زیر فشار بیشتر و بیشتر شبیه LRU رفتار می‌کند.

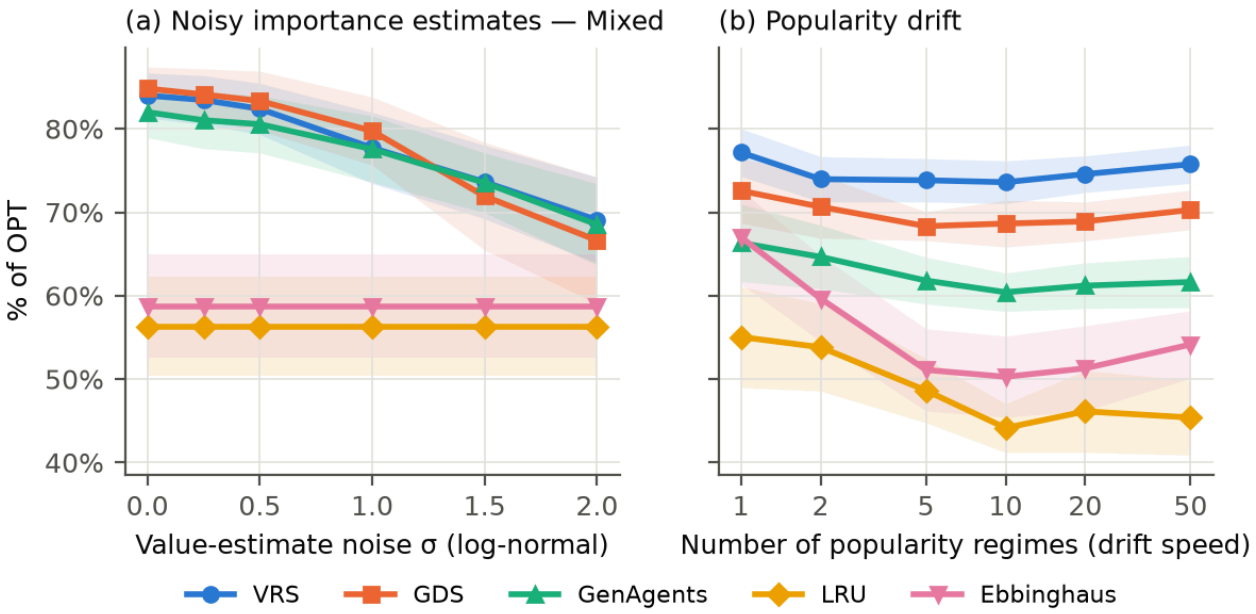
۷.۴ RQ3 — عملکرد با ظرفیت حافظه چگونه تغییر می‌کند؟



شکل ۳. نسبت مطلوبیت بر حسب بودجه حافظه برای هر بار کاری.

انتخاب سیاست وقتی حافظه کمیاب است بیشترین اهمیت را دارد. با میانگین روی بارهای کاری، برتری VRS بر LRU از ۲۸٫۴ واحد در $B = 2.5\%$ (۶۲٫۱ در برابر ۳۳٫۷ درصد) به ۷٫۸ واحد در $B = 40\%$ (۹۵٫۹ در برابر ۸۸٫۱ درصد) کاهش می‌یابد. به همین ترتیب، پیشتازی VRS بر GDS در بودجه‌های کوچک بیشترین است (۵٫۵+ واحد در ۲٫۵ درصد) و در بودجه‌های ۲۰ درصد و بیشتر، که همه سیاست‌های آگاه از ارزش از ۸۵ درصد بهینه فراتر می‌روند، از بین می‌رود. حافظه ایجنت در عمل در رژیم کمیابی قرار دارد: دستیار مستقر بسیار بیشتر از آنچه در هر بودجه بازیابی یا پرامپت جا شود محتوا جمع می‌کند. با فشرده‌سازی، VRS+C حتی در $B = 2.5\%$ به ۶۸٫۹ درصد بهینه می‌رسد. بار کاری محلیت زمانی باز هم استثناست: سیاست‌های مبتنی بر تازگی در هر بودجه‌ای غالب‌اند، پس انتخاب سیاست باید الگوی دسترسی مورد انتظار را بازتاب دهد (بخش ۸).

۷.۵ RQ4 — استحکام در برابر نویز تخمین و رانش



شکل ۴. (الف) نسبت مطلوبیت بر حسب نویز تخمین ارزش در بار کاری ترکیبی. (ب) نسبت مطلوبیت بر حسب سرعت رانش (تعداد رژیم‌های محبوبیت).

نویز ارزش (الف). همه سیاست‌های آگاه از ارزش با نویزی‌تر شدن تخمین‌ها افت می‌کنند، همان‌طور که نتیجه ۱ پیش‌بینی می‌کند، اما این افت تدریجی است. حتی در $\sigma = 2$، که تخمین معمول با ضریب $e^2 \approx 7$ خطا دارد، VRS در بار کاری ترکیبی ۶۹٫۱ درصد بهینه را حفظ می‌کند در برابر ۵۶٫۳ درصد برای LRU. در ۵۹٫۵ IRM در برابر ۴۹٫۹ درصد؛ در نادر-حیاتی ۶۴٫۵ در برابر ۵۰٫۹ درصد. در IRM و نادر-حیاتی، VRS در هر سطح نویز بر GDS غالب است (پیوست د). بنابراین سیگنال اهمیت خام بسیار بهتر از نبود آن است، و بهبود کیفیتش مستقیماً به مطلوبیت تبدیل می‌شود.

رانش (ب). سیاست‌های بی‌توجه به ارزش در برابر تغییر علایق شکننده‌اند. از بار کاری ایستا تا ۱۰ رژیم محبوبیت، Ebbinghaus از ۶۷٫۰ به ۵۰٫۳ درصد و LRU از ۵۵٫۰ به ۴۴٫۱ درصد سقوط می‌کنند. VRS در هر سرعت رانش بین ۷۳٫۶ و ۷۷٫۲ درصد باقی می‌ماند و همواره ۴٫۵ تا ۵٫۵ واحد از GDS جلوتر است. VRS+C بین ۷۹٫۳ و ۸۱٫۹ درصد می‌ماند. تخمین‌گر نرخ تنزیل‌شده (نیمه‌عمر ۱۰۰ گام) فراهم‌کننده این سازگاری است: بدون آن ($h = \infty$)، عملکرد اعتبارسنجی ۴٫۸ واحد افت می‌کند (پیوست ه).

۷.۶ RQ5 — آیا فشرده‌سازی کمک می‌کند؟

جدول ۲. اثر فشرده‌سازی ($\rho = 0.25$، $\gamma = 0.6$)، به‌صورت درصد OPT فقط-حذف در $B = 10\%$.

سیاست	IRM (ایستا)	محلیت زمانی	نادر-حیاتی	رانش	دستیار ترکیبی	میانگین
LRU	49.9 ± 6.3	90.1 ± 1.9	50.9 ± 6.7	48.6 ± 6.2	56.3 ± 9.6	59.2 ± 4.2
LRU+C	50.0 ± 6.3	90.2 ± 1.9	51.0 ± 6.7	48.7 ± 6.0	56.4 ± 9.7	59.3 ± 4.1
GenAgents	64.1 ± 4.1	**90.6 ± 1.2**	67.7 ± 6.8	61.8 ± 4.5	80.6 ± 5.5	72.9 ± 2.6
GenAgents+C	74.3 ± 1.7	84.6 ± 1.7	75.6 ± 3.2	72.0 ± 2.4	75.9 ± 5.3	76.5 ± 1.6
VRS	76.8 ± 3.9	78.5 ± 1.7	78.6 ± 4.9	73.8 ± 4.2	82.4 ± 4.9	78.0 ± 2.4
VRS+C	**82.5 ± 3.0**	81.8 ± 1.8	**82.9 ± 4.0**	**79.3 ± 3.0**	**85.3 ± 4.4**	82.4 ± 2.0

فشرده‌سازی فقط وقتی کمک می‌کند که با انتخاب خوب چه چیزی برای فشرده‌سازی همراه شود. LRU+C از LRU قابل‌تمایز نیست (۰٫۱+ واحد): LRU آیتمی با کمترین استفاده اخیر را فشرده می‌کند که معمولاً دیگر هرگز لازم نمی‌شود، پس فضای آزادشده صرف آیتم‌هایی با ارزش به همان اندازه کم می‌شود. GenAgents+C به‌طور میانگین ۳٫۶ واحد سود می‌کند اما در بار کاری زمانی ۶٫۰ واحد *ضرر* می‌کند. VRS+C در هر بار کاری و در هر یک از ۵۰ جفت بار کاری–بذر بر VRS بهبود می‌یابد (۴٫۴+ واحد، $p < 10^{-15}$). در مجموع بهترین سیاست است (۸۲٫۴ درصد)، در چهار بار کاری از پنج بهترین است و به‌طور معنادار بهتر از GDS است (۴٫۶+ واحد در $B = 10\%$، $p < 10^{-4}$؛ ۵٫۵+ واحد روی همه بودجه‌ها، $p < 10^{-16}$). نرخ برخوردش از ۵۱٫۰ به ۶۴٫۲ درصد می‌رسد. چون فشرده‌سازی مجموعه امکان‌پذیر را بزرگ می‌کند، OPT فقط-حذف کران بالای سیاست‌های فشرده‌ساز نیست: نسبت‌های جدول ۲ سود نسبت به بهترین زمان‌بندی فقط-حذف را می‌سنجند، نه فاصله تا بهینه آگاه از فشرده‌سازی، که به کار آینده واگذار می‌کنیم.

۷.۷ مطالعات حذفی

جدول ۳. مطالعات حذفی VRS: درصد OPT در $B = 10\%$ وقتی یک عامل شاخص حذف شود.

سیاست	IRM (ایستا)	محلیت زمانی	نادر-حیاتی	رانش	دستیار ترکیبی	میانگین
VRS	**76.8 ± 3.9**	**78.5 ± 1.7**	**78.6 ± 4.9**	**73.8 ± 4.2**	**82.4 ± 4.9**	78.0 ± 2.4
VRS-noRate	70.8 ± 3.9	63.5 ± 3.6	72.2 ± 5.6	68.4 ± 3.2	71.7 ± 8.8	69.3 ± 2.1
VRS-noValue	65.8 ± 4.2	77.3 ± 4.0	64.5 ± 6.3	61.9 ± 5.1	63.5 ± 10.9	66.6 ± 3.7
VRS-noSize	71.4 ± 5.0	75.6 ± 2.1	74.3 ± 5.1	67.8 ± 5.5	80.2 ± 6.1	73.9 ± 3.1

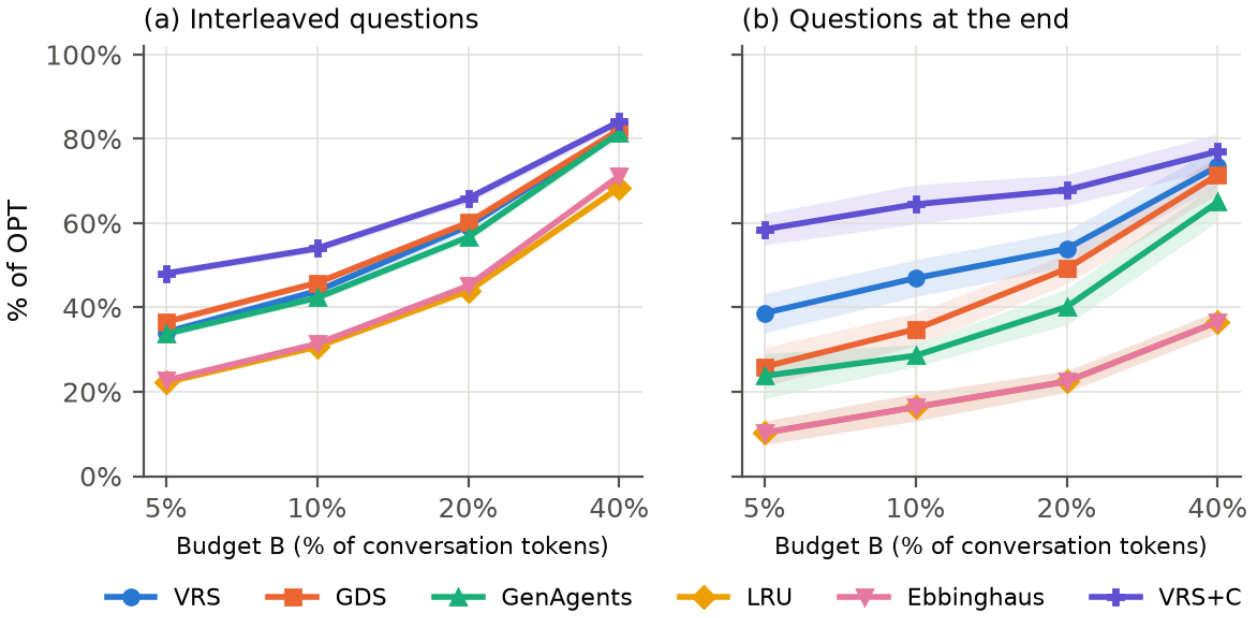
حذف هر عامل شاخص آسیب می‌زند، و ترتیب زیان‌ها با نظریه منطبق است. حذف **ارزش** بیشترین هزینه را دارد (۱۱٫۴- واحد به‌طور میانگین و ۱۵٫۶- در نادر-حیاتی)، همان‌طور که قضیه ۳ پیش‌بینی می‌کند. حذف **نرخ** ۸٫۷ واحد هزینه دارد، بیشترین در بار کاری زمانی (۱۵٫۰-) که در آن تخمین نرخ حامل سیگنال تازگی است. حذف **اندازه** ۴٫۱ واحد هزینه دارد، زیرا در این حالت یک آیتم بزرگ کم‌ارزش جای چند آیتم کوچک باارزش را می‌گیرد. هر سه عامل $\hat{\lambda}_i \hat{v}_i / s_i$ سهم دارند، که شاخص ضربی استخراج‌شده در بخش ۴.۳ را توجیه می‌کند.

۷.۸ RQ6 — آیا یافته‌ها در مکالمات واقعی برقرارند؟

داده. از [28] LoCoMo استفاده می‌کنیم: بنچمارکی از ۱۰ مکالمه بسیار بلندمدت بین دو نفر (۱۹ تا ۳۲ جلسه هر یک، ۳۶۹ تا ۶۸۹ نوبت گفتگو در هر مکالمه، در مجموع ۵,۸۸۲ نوبت). حاشیه‌نویسی‌های پرسش و پاسخ آن برای هر پرسش مشخص می‌کنند کدام نوبت‌های گفتگو شواهد پاسخ را دارند. از ۱,۵۳۵ پرسش با حاشیه‌نویسی شواهد معتبر استفاده می‌کنیم و طبق رویه معمول دسته خصمانه را کنار می‌گذاریم.

ساخت رد. هر نوبت گفتگو یک آیتم حافظه است، با اندازه برابر طولش بر حسب توکن (تخمین: تعداد نویسه‌ها / ۴؛ میانه ۳۰ توکن، در مجموع ۲۰۴,۸۸۰ توکن) و ارزش واقعی ۱. هر پرسش برای هر یک از نوبت‌های شاهدش یک درخواست تولید می‌کند، پس مطلوبیت یک سیاست برابر **تعداد بازیابی‌های شواهدی است که می‌تواند پاسخ دهد.** LoCoMo همه پرسش‌ها را پس از آخرین جلسه مطرح می‌کند. دو پروتکل را ارزیابی می‌کنیم: **پایانی**، که از بنچمارک پیروی می‌کند (همه پرسش‌ها پس از آخرین جلسه)، و **درهم‌تنیده**، که در آن هر پرسش پس از جلسه‌ای تصادفی و یکنواخت در یا پس از آخرین جلسه شاهدش پرسیده می‌شود، تا نیاز به بازیابی در حین ادامه مکالمه پدید آید (۱۰ زمان‌بندی تصادفی برای هر مکالمه). بودجه‌ها ۵، ۱۰، ۲۰ و ۴۰ درصد توکن‌های مکالمه‌اند. اوراکل دقیق همه ۴۴۰ نمونه را به‌طور بهینه حل می‌کند (بیشینه شکاف MIP کمتر از 10^{-15}).

پیش‌بینی آنلاین اهمیت. تخمین‌های ارزش $\hat{v}_i$ از یک LLM (Gemini 2.5 Flash، دمای ۰) می‌آیند که به هر نوبت از ۱ تا ۱۰ امتیاز می‌دهد که چقدر احتمال دارد بعداً لازم شود. مدل فقط جلسه خود نوبت را می‌بیند و هرگز پرسش‌ها را نمی‌بیند، پس پیش‌بینی به‌صورت آنلاین در زمان درج در دسترس است (پرامپت در پیوست و). امتیازها به $\hat{v}_i = e^{(\text{score}-5.5)/1.5}$ نگاشته می‌شوند. **پیش‌بینی‌ها آگاهی‌بخش‌اند:** نوبت‌های شاهد را با AUC برابر ۰٫۸۲۵ از سایر نوبت‌ها جدا می‌کنند و کالیبراسیون یکنواست. از نوبت‌هایی که امتیاز ۱ گرفته‌اند، ۳٫۴ درصد بعداً به‌عنوان شاهد لازم می‌شوند؛ از آن‌هایی که امتیاز ۱۰ گرفته‌اند، ۷۰٫۱ درصد. به‌عنوان کنترل، هر سیاست آگاه از ارزش بدون LLM (با $\hat{v}_i$ ثابت) نیز اجرا می‌شود. همه سیاست‌ها از ابرپارامترهای تنظیم‌شده روی بذرهای اعتبارسنجی مصنوعی استفاده می‌کنند؛ **هیچ چیزی روی LoCoMo تنظیم نشده است.**



شکل ۶. LoCoMo: مطلوبیت به‌صورت درصد OPT بر حسب بودجه حافظه، برای پرسش‌های درهم‌تنیده (الف) و پرسش‌های پایانی (ب). نوارهای سایه‌دار: بازه اطمینان ۹۵ درصد.

جدول ۵. LoCoMo، پروتکل درهم‌تنیده: درصد OPT (میانگین ± انحراف معیار روی ۱۰ مکالمه × ۱۰ زمان‌بندی) و یادآوری شواهد در $B = 10\%$.

سیاست	B = 5%	B = 10%	B = 20%	B = 40%	یادآوری شواهد در ٪۱۰
Random	19.4 ± 3.5	25.3 ± 3.3	37.7 ± 3.9	60.0 ± 4.1	21.1%
FIFO	21.2 ± 3.5	29.6 ± 3.5	42.0 ± 3.6	64.1 ± 5.7	24.6%
LRU	22.2 ± 3.8	30.7 ± 3.9	43.9 ± 4.7	68.5 ± 5.9	25.6%
LFU	19.0 ± 3.7	29.5 ± 4.7	45.4 ± 5.6	71.6 ± 5.5	24.7%
Ebbinghaus	22.7 ± 3.9	31.4 ± 4.1	45.1 ± 5.3	71.2 ± 5.6	26.2%
GDS	36.6 ± 4.3	45.9 ± 4.4	60.1 ± 6.2	82.1 ± 6.0	38.4%
GenAgents	33.8 ± 4.5	42.3 ± 3.9	56.7 ± 5.5	81.5 ± 5.7	35.3%
ImpDecay	33.0 ± 5.5	42.6 ± 4.6	58.4 ± 6.6	81.9 ± 5.6	35.6%
VRS	34.1 ± 5.7	43.9 ± 5.1	59.3 ± 6.1	82.0 ± 5.9	36.8%
VRS+C	48.1 ± 3.8	54.0 ± 4.6	65.9 ± 5.6	84.1 ± 5.6	56.4%
GenAgents+C	**53.5 ± 4.4**	**60.8 ± 4.6**	**70.3 ± 3.6**	**86.7 ± 4.0**	79.0%
GDS (بدون LLM)	18.1 ± 3.3	25.8 ± 3.5	39.4 ± 5.0	62.4 ± 6.0	21.5%
VRS (بدون LLM)	12.6 ± 4.1	18.7 ± 4.6	31.3 ± 5.1	58.7 ± 6.1	15.5%

جدول پروتکل پایانی در پیوست د.۵ آمده است. پنج یافته پدید می‌آید.

(۱) شکاف آگاهی از ارزش روی داده واقعی تکرار می‌شود. در $B = 10\%$، هر سیاست بی‌توجه به ارزش (LRU، LFU، FIFO، Ebbinghaus) به ۳۰ تا ۳۱ درصد OPT می‌رسد، به‌سختی بالاتر از حذف تصادفی (۲۵ درصد). هر سیاست آگاه از

ارزش به ۴۲ تا ۴۶ درصد می‌رسد. در پروتکل پایانی، FIFO، LFU، LRU و Ebbinghaus به یک سیاست واحد تبدیل می‌شوند، چون پیش از رسیدن پرسش‌ها هیچ خاطره‌ای دسترسی نمی‌شود، و همه به ۱۶ درصد OPT می‌رسند؛ VRS به ۴۷ درصد.

(۲) اهمیت پیش‌بینی‌شده توسط LLM بزرگ‌ترین اهرم منفرد است. حذف سیگنال LLM به‌طور میانگین روی بودجه‌ها برای ۱۹٫۸ GDS واحد و برای ۲۴٫۵ VRS واحد هزینه دارد (پروتکل درهم‌تنیده؛ Wilcoxon جفتی روی ۴۰۰ نمونه، هر دو $p < 10^{-60}$، برنده در ۱۰۰ درصد نمونه‌ها). بدون آن، VRS حتی *پایین‌تر* از LRU قرار می‌گیرد: در مکالمات واقعی، تاریخچه دسترسی یک نوبت پیش از نخستین بازیابی‌اش اطلاعاتی ندارد، و عامل اندازه به‌تنهایی نوبت‌های کوتاه را ترجیح می‌دهد که بیشترشان گپ‌اند. این نتیجه ۱ در عمل است. کیفیت پیش‌بینی‌کننده ارزش، نه قاعده حذف، بخش عمده مطلوبیت قابل‌دستیابی را تعیین می‌کند.

(۳) هیچ قاعده حذفی غالب نیست. با پرسش‌های درهم‌تنیده، GDS اندکی از VRS جلوتر است (۱٫۳- واحد روی همه بودجه‌ها، $p < 10^{-13}$)، در حالی که VRS بر GenAgents برتری دارد (۱٫۳+، $p < 10^{-7}$). با پرسش‌های پایانی، VRS با ۷٫۹ واحد از GDS (برنده در ۹۰ درصد نمونه‌ها، $p < 10^{-6}$) و با ۱۳٫۹ واحد از GenAgents جلوتر است. تفاوت از نحوه استفاده سیاست‌ها از تازگی ناشی می‌شود. جمله پیرشدگی GDS آیتم‌های تازه را ترجیح می‌دهد، که وقتی پرسش‌ها به‌زودی پس از شواهدشان می‌آیند کمک می‌کند. تخمین نرخ VRS پیش از نخستین پرسش هیچ تاریخچه دسترسی برای یادگیری ندارد، پس به پیش‌بینی LLM تکیه می‌کند، که وقتی پرسش‌ها دیر می‌آیند کمک می‌کند. مطالعه حذفی با این توضیح سازگار است: در پروتکل پایانی، VRS-noRate هم‌اندازه یا بهتر از VRS است (۴۸٫۷ در برابر ۴۷٫۰ درصد در ۱۰ درصد).

(۴) فشرده‌سازی آگاه از ارزش مؤثرترین مداخله است. در $B = 10\%$، فشرده‌سازی آگاه از ارزش با پرسش‌های درهم‌تنیده ۲٫۲ تا ۳٫۱ برابر LRU شواهد نگه می‌دارد (۵۶ تا ۷۹ درصد در برابر ۲۶ درصد یادآوری شواهد) و با پرسش‌های پایانی ۵ تا ۷ برابر (۴۷ تا ۶۳ درصد در برابر ۹ درصد). LRU+C باز هم سودی نمی‌برد. در GenAgents+C، LoCoMo اندکی از VRS+C بهتر است، در حالی که در داده مصنوعی ترتیب برعکس است (جدول ۲). توضیحی محتمل، که آن را به‌طور تجربی جدا نکرده‌ایم، این است که جمله تازگی جمعی آن فشرده‌سازی را به‌جای تمرکز روی نوبت‌های کم‌ارزش، روی نوبت‌های قدیمی‌تر پخش می‌کند. انتخاب بین سیاست‌های فشرده‌ساز آگاه از ارزش به بار کاری بستگی دارد، اما شکاف بین سیاست‌های آگاه و بی‌توجه به ارزش چنین نیست.

(۵) داده واقعی دشوارتر از بارهای کاری مصنوعی ماست. در $B = 10\%$، بهترین سیاست فقط-حذف در LoCoMo به ۴۶ تا ۴۷ درصد OPT می‌رسد، در برابر ۷۸ تا ۸۳ درصد در بارهای کاری مصنوعی. مکالمات واقعی دسترسی مجدد پراکنده‌تری دارند: ۷۶ درصد همه نوبت‌ها هرگز لازم نمی‌شوند و ۵۹ درصد نوبت‌های شاهد دقیقاً یک بار لازم می‌شوند (به‌طور میانگین حدود ۱٫۶۵ درخواست برای هر نوبت شاهد). بنابراین قضیه ۵ بهای پیش‌آگاهی بزرگ‌تری پیش‌بینی می‌کند. سیگنال‌های ارزش نیز ناقص‌اند (AUC برابر ۰٫۸۳). هر دو اثر جای قابل‌توجهی برای پیش‌بینی‌کننده‌های ارزش بهتر و برای فشرده‌سازی باقی می‌گذارند، اما نه برای قواعد تازگی زیرکانه‌تر.

۷.۹ تحلیل حساسیت

پارامترهای فشرده‌سازی. اندازه خلاصه $\rho \in \{0.1, 0.25, 0.5\}$ و ارزش حفظ‌شده $\gamma \in \{0.3, 0.6, 0.9\}$ (با $\gamma > \rho$) را برای سه سیاست فشرده‌ساز آگاه از ارزش تغییر می‌دهیم (پیوست د.۹). سود فشرده‌سازی با افزایش چگالی γ/ρ رشد می‌کند،

همان‌طور که بخش ۴.۵ پیش‌بینی می‌کند: VRS+C از ۷۸٫۱ درصد OPT فقط-حذف در $(\rho, \gamma) = (0.25, 0.3)$ تا ۹۹٫۲ درصد در $(0.1, 0.9)$ تغییر می‌کند. VRS+C در پنج تنظیم با $\gamma \leq 0.6$ بهترین سیاست فشرده‌ساز است. وقتی خلاصه‌ها ۹۰ درصد ارزش را حفظ می‌کنند، GDS+C ۱٫۳ تا ۳٫۲ واحد بهتر است و GenAgents+C در دو تنظیم از سه تنظیم بهتر است. با چنین فشرده‌سازی ارزان و تقریباً بی‌اتلافی، اینکه چه *چیزی* فشرده شود کمتر از خود فشرده‌سازی اهمیت دارد؛ در این رژیم سیاست‌های فشرده‌ساز می‌توانند از OPT فقط-حذف فراتر روند (تا ۱۰۱ درصد).

توزیع‌های بار کاری. در بارهای کاری IRM و ترکیبی، پراکندگی ارزش (لگ‌نرمال با $\sigma \in \{0.5, 1, 2\}$)، دم محبوبیت (شکل Pareto $\in \{1.1, 1.5, 3\}$)، پراکندگی اندازه ($\sigma \in \{0.3, 0.6, 1\}$) و، برای بار کاری ترکیبی، ضریب ارزش آیتم‌های حیاتی ($\in \{10, 30, 100\}$) را تغییر می‌دهیم. در همه ۱۶ پیکربندی متمایز (پیوست د.۹)، **نتیجه‌گیری‌های کیفی تغییر نمی‌کنند.** VRS+C در همه پیکربندی‌ها بهترین سیاست است و GDS، VRS و VRS+C در همه پیکربندی‌ها از هر سیاست بی‌توجه به ارزش بهتر عمل می‌کنند. تنها استثنا در میان سیاست‌های آگاه از ارزش، GenAgents در پراکندگی ارزش پایین است (IRM، $\sigma = 0.5$)، که در آن جمله تازگی جمعی‌اش غالب می‌شود و پایین‌تر از Ebbinghaus قرار می‌گیرد (۵۶٫۳ در برابر ۶۰٫۳ درصد). VRS در همه گونه‌های IRM بر GDS برتری دارد (۱٫۹+ تا ۶٫۱+ واحد) و در همه گونه‌های ترکیبی اندکی عقب است (۰٫۱- تا ۱٫۷- واحد)، مانند نتایج اصلی. برتری آگاهی از ارزش با پراکندگی ارزش رشد می‌کند: در IRM، فاصله VRS و LRU از ۱۶٫۴ واحد در $\sigma = 0.5$ به ۴۴٫۰ واحد در $\sigma = 2$ می‌رسد. LRU تحت محبوبیت دم‌سنگین (شکل ۱٫۱)، که در آن آیتم‌های پرتکرار معمولاً تازه هم هستند، رقابتی‌ترین و تحت دم سبک (شکل ۳٫۰) کمترین رقابت‌پذیری را دارد و در IRM به ۴۱٫۵ درصد OPT سقوط می‌کند.

---

۸. بحث

رهنمودهای عملی. نتایج مصنوعی و واقعی ما شش توصیه برای توسعه‌دهندگان ایجنت را پشتیبانی می‌کنند. (۱) **از سیاست‌های بی‌توجه به ارزش** (FIFO، LRU، منحنی‌های فراموشی) برای خاطراتی که ممکن است به ایمنی مربوط باشند **استفاده نکنید**؛ در بارهای کاری مصنوعی واقعیت‌های حیاتی را بیش از حذف تصادفی فراموش می‌کنند و در مکالمات واقعی به‌سختی از آن بهترند. (۲) **ابتدا روی پیش‌بینی‌کننده ارزش سرمایه‌گذاری کنید.** در LoCoMo، امتیاز اهمیت LLM بدون هیچ آموزشی ۱۲ تا ۲۵ واحد مطلوبیت اضافه می‌کند، بیش از هر تغییری در قاعده حذف. (۳) **سیگنال ارزش را به‌صورت ضربی با تخمین نرخ ترکیب و بر اندازه نرمال کنید** (VRS) وقتی آیتم‌ها مکرراً دسترسی می‌شوند؛ GDS، که تغییری یک‌خطی از LRU است، جایگزینی قوی و ساده‌تر است، به‌ویژه وقتی نیاز به بازیابی به‌زودی پس از شکل‌گیری خاطره پدید می‌آید. (۴) **وقتی حافظه را کانتکست کوتاه‌عمر غالب کرده است**، مانند یادداشت‌های موقت درون یک کار، سیاست‌های متکی بر تازگی مانند GDS یا GenAgents رقابت‌پذیر و ارزان‌ترند. (۵) **پیش از فراموش کردن، فشرده کنید**، اما فقط با قاعده انتخاب آگاه از ارزش: فشرده‌سازی آگاه از ارزش در مکالمات واقعی ۲ تا ۵ برابر LRU شواهد نگه می‌دارد، در حالی که فشرده‌سازی مبتنی بر LRU سودی ندارد. (۶) **مطلوبیت نسبت به OPT را گزارش کنید، نه نرخ برخورد را**: این دو می‌توانند سیاست‌ها را به ترتیب‌های متضاد رتبه‌بندی کنند.

پیامدها برای طراحی بنچمارک. چون بهینه پیش‌آگاه برای اندازه‌های واقع‌گرایانه رد قابل محاسبه است، توصیه می‌کنیم مقالات حافظه ایجنت مطلوبیت را **به‌صورت درصدی از OPT** در کنار recall خام گزارش کنند. این کار نتایج را بین بارهای

کاری و بودجه‌ها قابل مقایسه می‌کند و نشان می‌دهد چه مقدار جای پیشرفت باقی است.

فراموشی یک قضاوت ارزشی است. قضیه‌های ۲ و ۳ نشان می‌دهند هیچ مقدار مهندسی روی سیگنال‌های تازگی و تکرار نمی‌تواند جایگزین تخمینی از *آنچه مهم است* شود. بنابراین امیدبخش‌ترین مسیر برای حافظه ایجنت، تخمین بهتر ارزش است: از داوران LLM، بازخورد کاربر یا نتایج کار. چارچوب ما کیفیت این تخمین را به کمیتی قابل اندازه‌گیری تبدیل می‌کند (نتیجه ۱، بخش‌های ۷.۵ و ۷.۸).

ارتباط با حافظه انسان. منحنی‌های فراموشی روان‌شناسی توصیف می‌کنند انسان‌ها کی فراموش می‌کنند، اما حافظه انسان به‌شدت با برجستگی هیجانی و ارتباط نیز تعدیل می‌شود که متناظر با ارزش‌اند. نتایج ما نشان می‌دهد خاطرات ایجنتی که فقط بر اساس منحنی فراموشی مدل شده‌اند، حالت شکست آن را بدون سازوکارهای جبرانی‌اش به ارث می‌برند.

۹. محدودیت‌ها

- **دامنه مطالعه داده واقعی.** ارزیابی داده واقعی ما از یک بنچمارک (LoCoMo: ۱۰ مکالمه، ۵,۸۸۲ نوبت)، ارزش‌های واقعی یکنواخت و پروتکل زمان‌بندی نیمه‌مصنوعی برای حالت درهم‌تنیده استفاده می‌کند، زیرا LoCoMo همه پرسش‌ها را در پایان مطرح می‌کند. ایجنت‌های مستقر ردهای غنی‌تری تولید می‌کنند (خروجی ابزارها، اسناد، حافظه‌های چندکاربره). MemSim هر رد رویدادی را می‌پذیرد، و بازپخش لاگ‌های تولیدی مهم‌ترین گام بعدی است.
- **یک پیش‌بینی‌کننده ارزش.** از یک LLM و یک پرامپت برای پیش‌بینی اهمیت استفاده می‌کنیم؛ مدل‌ها، پرامپت‌ها یا پیش‌بینی‌کننده‌های آموخته‌شده دیگر ممکن است اعداد مطلق را تغییر دهند، هرچند نتیجه ۱ پیش‌بینی می‌کند مطلوبیت چگونه با کیفیت پیش‌بینی‌کننده تغییر می‌کند.
- **تخمین‌های ارزش.** نویز تخمین ارزش را در داده مصنوعی لگ‌نرمال و مستقل بین آیتم‌ها مدل می‌کنیم؛ اهمیت واقعی تعیین‌شده توسط LLM ممکن است به شیوه‌های همبسته سوگیری داشته باشد.
- **بازیابی دقیق.** فرض می‌کنیم آیتم نگه‌داشته‌شده همیشه هنگام نیاز بازیابی می‌شود. در عمل بازیابی نویزی است و با اندازه حافظه افت می‌کند، که انگیزه‌ای افزوده برای کوچک نگه‌داشتن حافظه ایجاد می‌کند.
- **مقیاس اوراکل.** ILP دقیق برای ردهای چند هزار رویدادی عملی است؛ ردهای بزرگ‌تر به کران LP نیاز دارند که نسبت‌های مطلوبیت محافظه‌کارانه (کران پایین) می‌دهد.
- **شکاف نظریه و عمل.** قضیه ۴ محبوبیت ایستا و معلوم را فرض می‌کند؛ VRS آن را به‌صورت آنلاین تخمین می‌زند و دسترسی‌های قدیمی را تنزیل می‌کند، که قضیه آن را پوشش نمی‌دهد.

۱۰. نتیجه‌گیری

مسئله حذف حافظه ایجنت را معرفی کردیم و نشان دادیم که برگشت‌ناپذیری فراموشی نظریه مدیریت حافظه را تغییر می‌دهد: قاعده Belady شکست می‌خورد، هیچ سیاست آنلاینی در بدترین حالت رقابتی نیست، و سیاست‌های بی‌توجه به ارزش، از جمله روش‌های ابتکاری تازگی و منحنی فراموشی که در عمل غالب‌اند، می‌توانند تقریباً تمام مطلوبیت قابل‌دستیابی را از دست بدهند. در مدل تصادفی، یک شاخص ساده ارزش–نرخ–اندازه به‌طور اثبات‌پذیر تقریباً بهینه است

و برگشت‌ناپذیری هزینه‌ای ندارد. به‌طور تجربی، در بارهای کاری مصنوعی، بهترین روش ابتکاری موجود ۲۲ درصد از مطلوبیت قابل‌دستیابی را بلااستفاده می‌گذارد، سیاست‌های بی‌توجه به ارزش تا ۸۶ درصد واقعیت‌های حیاتی را فراموش می‌کنند (بدتر از حذف تصادفی)، و شاخص ارزش–نرخ–اندازه همراه با فشرده‌سازی به ۸۲٫۴ درصد بهینه پیش‌آگاه می‌رسد و بیش از ۹۹ درصد واقعیت‌های حیاتی را به یاد می‌آورد. در مکالمات بلندمدت واقعی، همین تصویر با تضادی شدیدتر برقرار است: سیاست‌های بی‌توجه به ارزش به‌سختی از حذف تصادفی بهترند، امتیاز اهمیت LLM بدون آموزش بزرگ‌ترین اهرم منفرد است، و فشرده‌سازی آگاه از ارزش ۲ تا ۵ برابر LRU شواهد نگه می‌دارد. MemSim و اوراکل دقیق آن را منتشر می‌کنیم تا سامانه‌های حافظه ایجنت آینده نه‌تنها با یکدیگر، بلکه با آنچه قابل‌دستیابی است سنجیده شوند.

بیانیه تکرارپذیری

تمام کدها، مولدهای بار کاری، بذرهای تصادفی، شبکه‌های ابرپارامتر، امتیازهای اهمیت LLM و نتایج خام در https://github.com/AmirHosseinkhalife/agent-memory-eviction/tree/main/agent-memory-eviction منتشر شده‌اند. کل خط لوله با دستورهای زیر بازتولید می‌شود:

```
cd code
pip install -r requirements.txt
sh data/get_locomo.sh                    # LoCoMo benchmark
python tests/test_oracle.py              # oracle correctness checks
python -m memsim.experiments all         # tuning + all experiments (results/*.csv)
python -m memsim.figures                 # figures/*.pdf and results/tables.md
python -m memsim.figures_extra           # extended figures and results/tables_extra.md
```

داده LoCoMo با `data/get_locomo.sh` دانلود می‌شود. امتیازهای اهمیت LLM در `data/locomo/importance.json` کش شده‌اند، پس آزمایش داده واقعی بدون دسترسی به API تکرارپذیر است.

```
agent-memory-eviction/
├── paper.en.md, paper.fa.md   # the paper (English / Persian)
└── code/
    ├── memsim/
    │   ├── workloads.py       # IRM, temporal, rare-critical, drift, mixed
    │   ├── locomo.py, llm.py  # real-data traces and LLM importance scores
    │   ├── policies.py        # 8 baselines, VRS, ablations, DENSITY*, compression
    │   ├── simulator.py       # event-driven engine with irrevocable eviction
    │   ├── oracle.py          # ILP / LP offline optimum (HiGHS)
    │   ├── experiments.py     # tuning and experiment grids
    │   └── figures.py, figures_extra.py
    ├── tests/test_oracle.py
    ├── data/                  # LoCoMo download script, cached LLM scores
    ├── results/               # raw CSVs, hyper-parameters, tables
    └── figures/
```

بیانیه تأثیرات گسترده‌تر و اخلاق

سیاست‌های فراموشی با حریم خصوصی و ایمنی در تعامل‌اند. از یک سو، فراموشی عمدی از کمینه‌سازی داده و حق فراموش‌شدن پشتیبانی می‌کند؛ از سوی دیگر، فراموش کردن دستورالعمل حیاتی ایمنی یا محدودیت پزشکی کاربر می‌تواند آسیب‌زا باشد. نتایج ما نشان می‌دهد سیاست‌های بی‌توجه به ارزش به‌ویژه مستعد دومی‌اند و این ریسک را می‌توان پیش از استقرار کمّی کرد. تخمین‌های ارزش خود ممکن است سوگیری‌هایی درباره آنچه برای کاربران مختلف «مهم» است را رمزگذاری کنند؛ ممیزی آن‌ها مکملی مهم برای این کار است. این مطالعه از داده مصنوعی و یک بنچمارک عمومی (LoCoMo، مکالمات تولیدشده) استفاده می‌کند و آزمودنی انسانی ندارد.

مشارکت نویسندگان

امیرحسین خلیفه: طرح ایده، روش‌شناسی، تحلیل نظری، توسعه نرم‌افزار (MemSim)، انجام آزمایش‌ها و نگارش محتوای فنی. **مهدی غلامی:** همراهی در طول پروژه و آماده‌سازی متن انگلیسی مقاله. هر دو نویسنده نسخه نهایی را تأیید کرده‌اند.

مراجع

1. Belady, L. A. (1966). A study of replacement algorithms for a virtual-storage computer. *IBM Systems Journal*, 5(2), 78–101.
2. Sleator, D. D., & Tarjan, R. E. (1985). Amortized efficiency of list update and paging rules. *Communications of the ACM*, 28(2), 202–208.
3. Young, N. E. (1994). The k-server dual and loose competitiveness for paging. *Algorithmica*, 11(6), 525–541.
4. Cao, P., & Irani, S. (1997). Cost-aware WWW proxy caching algorithms. *USENIX Symposium on Internet Technologies and Systems*.
5. Bansal, N., Buchbinder, N., & Naor, J. (2012). A primal-dual randomized algorithm for weighted paging. *Journal of the ACM*, 59(4).
6. Marchetti-Spaccamela, A., & Vercellis, C. (1995). Stochastic on-line knapsack problems. *Mathematical Programming*, 68, 73–104.
7. Park, J. S., O'Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., & Bernstein, M. S. (2023). Generative Agents: Interactive simulacra of human behavior. *UIST 2023*. arXiv:2304.03442.
8. Packer, C., Wooders, S., Lin, K., Fang, V., Patil, S. G., Stoica, I., & Gonzalez, J. E. (2023). MemGPT: Towards LLMs as operating systems. *arXiv:2310.08560*.
9. Zhong, W., Guo, L., Gao, Q., Ye, H., & Wang, Y. (2024). MemoryBank: Enhancing large language models with long-term memory. *AAAI 2024*. arXiv:2305.10250.
10. Chhikara, P., Khant, D., Aryan, S., Singh, T., & Yadav, D. (2025). Mem0: Building production-ready AI agents with scalable long-term memory. *arXiv:2504.19413*.
11. Xu, W., Liang, Z., Mei, K., et al. (2025). A-MEM: Agentic memory for LLM agents. *arXiv:2502.12110*.
12. Hu, Y., Liu, S., Yue, Y., et al. (2025). Memory in the age of AI agents. *arXiv:2512.13564*.

13. Wei, L., Peng, X., Dong, X., et al. (2026). FadeMem: Biologically-inspired forgetting for efficient agent memory. *arXiv:2601.18642*.
14. Yang, N., Li, S., Shen, M., et al. (2026). SF-AMS: Strategic forgetting for structured memory in LLM agent. *arXiv:2607.22562*.
15. Rusu, T., Khanzadeh, S., & Alalfi, M. (2026). Selective forgetting: A graph-based memory framework for long-term LLM agents. *arXiv:2608.28978*.
16. Chen, Z., & Cheng, Q. (2026). Learning what to remember: A cognitively grounded multi-factor value model for agentic memory. *arXiv:2606.12945*.
17. Colaco, A. G., & Lahjouji, N. (2026). What to keep, what to forget: A rate–distortion view of memory compaction in LLMs and agents. *arXiv:2607.08032*.
18. Matam, V., & Kim, K. (2026). MemDecay: Region-aware KV cache eviction for efficient LLM agent inference. *arXiv:2607.10582*.
19. Liu, Y., Yu, M., & Yang, J. (2026). When fancy eviction fails: Rethinking cache replacement for LLM prefix reuse. *arXiv:2609.28870*.
20. Zhu, L., Lin, Y., Wang, Y., et al. (2026). Will my assistant remember my allergy? What personal LLM assistants forget when conversation memory is compressed. *arXiv:2609.05767*.
21. Yao, A. C.-C. (1977). Probabilistic computations: Toward a unified measure of complexity. *FOCS 1977*, 222–227.
22. Ahuja, R. K., Magnanti, T. L., & Orlin, J. B. (1993). *Network Flows: Theory, Algorithms, and Applications*. Prentice Hall.
23. Alqithami, S. (2025). Forgetful but faithful: A cognitive memory architecture and benchmark for privacy-aware generative agents. *arXiv:2512.12856*.
24. Song, M. (2026). When retrieval fails before it begins: Structurally indirect prerequisite eviction as a retention failure in agentic memory. *arXiv:2608.20400*.
25. Iwama, K., & Taketomi, S. (2002). Removable online knapsack problems. *ICALP 2002*, LNCS 2380, 293–305.
26. Lykouris, T., & Vassilvitskii, S. (2018). Competitive caching with machine learned advice. *ICML 2018*. arXiv:1802.05399.
27. Purohit, M., Svitkina, Z., & Kumar, R. (2018). Improving online algorithms via ML predictions. *NeurIPS 2018*.
28. Maharana, A., Lee, D.-H., Tulyakov, S., Bansal, M., Barbieri, F., & Fang, Y. (2024). Evaluating very long-term conversational memory of LLM agents. *ACL 2024*. arXiv:2402.17753.
29. Boucheron, S., Lugosi, G., & Massart, P. (2013). *Concentration Inequalities: A Nonasymptotic Theory of Independence*. Oxford University Press.
30. Raab, M., & Steger, A. (1998). "Balls into bins" — A simple and tight analysis. *RANDOM 1998*, LNCS 1518, 159–170.

پیوست

الف. اثبات‌ها

الف.۱ اثبات گزاره ۱. فرض کنید $B = 1$ و همه اندازه‌ها و ارزش‌ها برابر ۱ باشند. آیتم a در $t = 1$ و آیتم b در $t = 2$ وارد می‌شوند. درخواست‌ها: b یک بار در $t = 3$، سپس a در $t = 4, \dots, 3 + L$. در $t = 2$ حافظه از ظرفیت فراتر می‌رود. درخواست بعدی b (در $t = 3$) زودتر از a (در $t = 4$) است، پس قاعده «دورترین در آینده» a را حذف می‌کند و مطلوبیت ۱ می‌گیرد. نگه‌داشتن a به‌جای آن مطلوبیت L می‌دهد. پس نسبت $1/L$ است. □

الف.۲ اثبات قضیه ۱. *(الف)* کاهش از کوله‌پشتی ۰/۱. با آیتم‌هایی با اندازه s_i، سود p_i و ظرفیت B، نمونه‌ای از AMEP می‌سازیم که در آن آیتم‌های $1,\dots,n$ در زمان‌های $1,\dots,n$ با اندازه s_i و ارزش $v_i = p_i$ وارد می‌شوند و سپس برای هر آیتم یک درخواست در زمان‌های $n+1,\dots,2n$ می‌آید. هر مجموعه S با $\sum_{i\in S} s_i \le B$ را می‌توان در طول همه درخواست‌ها نگه داشت (هر آیتم خارج از S هنگام ورود حذف می‌شود) و $\sum_{i\in S} p_i$ کسب کرد. برعکس، آیتم‌هایی که در زمان n نگه داشته شده‌اند یک مجموعه امکان‌پذیر کوله‌پشتی‌اند و فقط آن‌ها می‌توانند مطلوبیت کسب کنند. پس مطلوبیت بهینه AMEP برابر سود بهینه کوله‌پشتی است.

(ب) اندازه‌های واحد را فرض کنید. شبکه جریانی با مسیر خط زمان $u_0 \to u_1 \to \cdots \to u_T$ بسازید که کمان‌هایش ظرفیت B و هزینه ۰ دارند. برای هر آیتم i با درخواست‌های $r_{i,1} < \cdots < r_{i,K_i}$، گره‌های زنجیره $c_{i,1},\dots,c_{i,K_i}$ را اضافه کنید؛ کمان ورودی $u_{a_i} \to c_{i,1}$ و کمان‌های زنجیره $c_{i,k} \to c_{i,k+1}$، هر کدام با ظرفیت ۱ و هزینه $-v_i$؛ و کمان‌های خروجی $c_{i,k} \to u_{r_{i,k}}$ با ظرفیت ۱ و هزینه ۰. B واحد از u_0 به u_T با کمترین هزینه بفرستید. زنجیره هر آیتم یک کمان ورودی واحد دارد، پس واحد جریانی که وارد آن می‌شود پیشوندی از درخواست‌هایش را دنبال می‌کند و پس از آخرین درخواستی که پاسخ می‌دهد خارج می‌شود. این دقیقاً یک بازه نگهداری برگشت‌ناپذیر است که به ازای هر درخواست پاسخ‌داده‌شده v_i کسب می‌کند. هر برش بین زمان‌های متوالی دقیقاً B واحد حمل می‌کند که بین کمان خط زمان و زنجیره‌هایی که از برش می‌گذرند تقسیم شده، پس در هر زمان حداکثر B آیتم نگه داشته می‌شود. برعکس، هر زمان‌بندی امکان‌پذیر چنین جریانی را القا می‌کند. ماتریس شبکه کاملاً تک‌پیمانه‌ای است، پس جریان کمینه‌هزینه صحیحی وجود دارد و در زمان چندجمله‌ای قوی محاسبه‌پذیر است [22]. □

الف.۳ اثبات قضیه ۲. اصل Yao [21] را به کار می‌بریم: کافی است توزیعی روی ورودی‌ها نشان دهیم که هر سیاست *قطعی* روی آن به‌طور مورد انتظار حداکثر $(B/n)\cdot \mathrm{OPT}$ کسب کند. n آیتم با اندازه و ارزش واحد در زمان‌های $1,\dots,n$ وارد می‌شوند. سپس $j^\ast$ را به‌طور یکنواخت از $\{1,\dots,n\}$ بکشید و آن را L بار درخواست کنید. حافظه M_n یک سیاست قطعی پیش از آشکار شدن $j^\ast$ ثابت است و $|M_n| \le B$، پس $\Pr[j^\ast \in M_n] \le B/n$. چون آیتم‌های حذف‌شده نمی‌توانند بازگردند، سیاست با احتمال حداکثر B/n مقدار L و در غیر این صورت ۰ کسب می‌کند، در حالی که $\mathrm{OPT} = L$ (نگه‌داشتن $j^\ast$). پس برای هر سیاست تصادفی، $j^\ast$ای وجود دارد که مطلوبیت مورد انتظار سیاست روی آن حداکثر $(B/n)\cdot L$ است. با $n \to \infty$ نسبت رقابتی بی‌کران می‌شود. □

الف.۴ اثبات قضیه ۳. n آیتم با اندازه واحد در زمان‌های $1,\dots,n$ وارد می‌شوند، همه با محبوبیت $w_i = 1$. یک آیتم $j^\ast$ که به‌طور یکنواخت تصادفی انتخاب شده ارزش V و بقیه ارزش ۱ دارند؛ تخمین‌های ارزش دقیق‌اند. گام‌های بعدی درخواست‌هایی تحت IRM ایستا هستند که هر کدام یک آیتم را به‌طور یکنواخت انتخاب می‌کنند. سیاست بی‌توجه به ارزش زمان‌های ورود، اندازه‌ها و تاریخچه دسترسی را مشاهده می‌کند که توزیع توأم آن‌ها به $j^\ast$ بستگی ندارد. پس M_t مستقل از $j^\ast$ است و $\Pr[j^\ast \in M_t] = \mathbb{E}|M_t|/n \le B/n$. پاداش مورد انتظارش در هر گام درخواست حداکثر $\frac{1}{n}\big(V\cdot \frac{B}{n} + B\big)$ است. DENSITY آیتم $j^\ast$ را اول رتبه‌بندی و همراه با $B-1$ آیتم دیگر برای همیشه نگه می‌دارد و در هر گام درخواست $\frac{1}{n}(V+B-1)$ کسب می‌کند. نسبت حداکثر $\frac{VB/n+B}{V+B-1}$ است که با $V\to\infty$ به B/n میل می‌کند؛ انتخاب V به اندازه کافی بزرگ $B/n+\varepsilon$ را می‌دهد. □

الف.۵ اثبات قضیه ۴ و نتیجه ۱.

لم (یکنوایی). هر ترتیب کلی اکید روی آیتم‌ها را ثابت کنید (بر اساس ϕ نزولی، با شکستن تساوی بر اساس اندیس). برای مجموعه A، $P(A)$ را طولانی‌ترین پیشوند A در این ترتیب تعریف کنید که اندازه کلش حداکثر B است. آنگاه $P(A \cup \{j\}) \setminus \{j\} \subseteq P(A)$.

اثبات. درج j در فهرست مرتب ترتیب نسبی سایر آیتم‌ها را تغییر نمی‌دهد و فقط می‌تواند اندازه تجمعی هر آیتم (اندازه کل خودش و همه آیتم‌های پیش از آن) را افزایش دهد. اگر آیتم $x \in A$ خارج از $P(A)$ باشد، آیتمی در جایگاه x یا پیش از آن در A اندازه تجمعی بیش از B دارد، و همان آیتم در $A \cup \{j\}$ نیز اندازه تجمعی بیش از B دارد. پس $x \notin P(A \cup \{j\})$. □

(۱) DENSITY قرار می‌دهد $M_t = P(A_t)$، و $A_t = A_{t-1} \cup \{j_t\}$. طبق لم، $M_t \setminus \{j_t\} \subseteq M_{t-1}$، پس DENSITY هرگز به آیتمی که حذف کرده نیاز پیدا نمی‌کند: به‌صورت برگشت‌ناپذیر قابل‌پیاده‌سازی است.

(۲) فرض کنید $\mathcal{F}_{t-1}$ تاریخچه پیش از گام t باشد. فرایند ورود برون‌زاست، پس A_t برای همه سیاست‌ها یکسان است. برای گام درخواست t و هر سیاست π که درخواست‌ها را پیش‌بینی نمی‌کند، M_t^π نسبت به $\mathcal{F}_{t-1}$ اندازه‌پذیر است و

$$\mathbb{E}[\text{reward}_t \mid \mathcal{F}_{t-1}] = \frac{1}{W(A_t)} \sum_{i \in M_t^\pi} w_i v_i \le \frac{\mathrm{FK}(A_t)}{W(A_t)},$$

که در آن $W(A_t) = \sum_{i \in A_t} w_i$ و $\mathrm{FK}(A)$ مقدار بهینه کوله‌پشتی کسری با سودهای $w_i v_i$، اندازه‌های s_i و ظرفیت B است. اگر $\sum_{i \in A_t} s_i \le B$، آنگاه $P(A_t) = A_t$ به FK می‌رسد. در غیر این صورت، c را نخستین آیتم خارج از $P = P(A_t)$ بگیرید. بهینگی حریصانه کوله‌پشتی کسری می‌دهد $\mathrm{FK}(A_t) = \sum_{i \in P} w_i v_i + \phi_c r$ و $r = B - \sum_{i \in P} s_i < s_c \le s_{\max}$. چون هر $i \in P$ دارای $\phi_i \ge \phi_c$ است، $\sum_{i \in P} w_i v_i \ge \phi_c (B - r)$، پس

$$\mathrm{FK}(A_t) \le \Big(\sum_{i \in P} w_i v_i\Big) \frac{B}{B - r} \quad \Longrightarrow \quad \sum_{i \in P} w_i v_i \ge \Big(1 - \frac{s_{\max}}{B}\Big) \mathrm{FK}(A_t).$$

جمع کران‌های هر گام روی گام‌های درخواست و گرفتن امید ریاضی ادعا را ثابت می‌کند. سیاست مقایسه‌شونده می‌تواند همه *ورودهای* آینده را بداند، زیرا $\mathrm{FK}(A_t)$ آن را مسیربه‌مسیر کران‌دار می‌کند.

نتیجه ۱. لم برای هر ترتیب ثابتی برقرار است، پس DENSITY با تخمین‌های $\hat{\phi}$ همچنان به‌صورت برگشت‌ناپذیر قابل‌پیاده‌سازی است. $\hat{P}$ را پیشوند آن و $\widehat{\mathrm{FK}}$ را کوله‌پشتی کسری با سودهای تخمینی بگیرید. آنگاه $\sum_{\hat{P}} w_i v_i \ge \frac{1}{1+\delta} \sum_{\hat{P}} \hat{w}_i \hat{v}_i \ge \frac{1}{1+\delta}\big(1 - \frac{s_{\max}}{B}\big)\widehat{\mathrm{FK}} \ge \frac{1-\delta}{1+\delta}\big(1 - \frac{s_{\max}}{B}\big)\mathrm{FK}$. □

الف.۶ اثبات قضیه ۵. *بهینگی DENSITY.* با اندازه‌های واحد، پیشوند حریصانه ظرفیت را دقیقاً پر می‌کند ($r = 0$ در الف.۵)، پس $\sum_{i \in P(A)} w_i v_i = \mathrm{FK}(A)$ و DENSITY به کران بالای هر سیاست آنلاین که در الف.۵ به دست آمد می‌رسد. با ورودهای ایستا، B آیتم با بزرگ‌ترین p_i را در تمام مدت نگه می‌دارد و به‌طور مورد انتظار $D = H \sum_{\text{top-}B} p_i$ کسب می‌کند.

(الف) N_i را تعداد درخواست‌های آیتم i بگیرید، پس $N_i \sim \mathrm{Bin}(H, p_i)$ با میانگین $\mu_i = H p_i$. بدون ورود بیشتر، کنار گذاشتن یک آیتم هرگز به بهینه پیش‌آگاه کمک نمی‌کند، پس $U(\mathrm{OPT}) = \max_{|S| \le B} \sum_{i \in S} N_i$. با $X_i = N_i - \mu_i$:

$$\max_{|S| \le B} \sum_{i \in S} N_i \;\le\; \max_{|S| \le B} \sum_{i \in S} \mu_i + \max_{|S| \le B} \sum_{i \in S} X_i \;\le\; D + B \cdot \max\big(0, \max_i X_i\big).$$

هر X_i مجموع H متغیر برنولی مرکزی مستقل محدود به ۱ است، پس در دم راست زیرگاما با عامل واریانس $Hp_i \le Hp$ و مقیاس $1/3$ است (نامساوی Bernstein). نامساوی بیشینه برای متغیرهای زیرگاما [29، نتیجه ۲.۶]، اعمال‌شده بر $n+1$ متغیر $X_1,\dots,X_n,0$، می‌دهد $\mathbb{E}[\max(0,\max_i X_i)] \le \sqrt{2Hp\ln(n+1)} + \frac{1}{3}\ln(n+1)$. تقسیم بر D (الف) را ثابت می‌کند؛ برای محبوبیت یکنواخت، $D = BH/n$ و $p = 1/n$.

(ب) با $B=1$، $H=n$ و محبوبیت یکنواخت، DENSITY مقدار $D=1$ کسب می‌کند، در حالی که $U(\mathrm{OPT}) = \max_i N_i$ بیشینه بار هنگام پرتاب n توپ در n سطل است که امیدش $(1+o(1))\ln n/\ln\ln n$ است [30]. □

ب. جزئیات مولد بار کاری

پارامتر	مقدار
افق T	۳۰۰۰ رویداد
احتمال ورود در هر گام	۰٫۳ (حدود ۹۰۰ آیتم و ۲۱۰۰ درخواست در هر رد)
اندازه آیتم	LogNormal(ln 50, 0.6)، توکن، محدود به [8, 400]
ارزش واقعی v_i	LogNormal(0, 1)
محبوبیت پایه λ_i	1 + Pareto(1.5)
تخمین ارزش $\hat{v}_i$	$v_i \cdot \exp(\mathcal{N}(0, 0.5^2))$
زوال زمانی	$w_i(t) = \lambda_i e^{-(t-a_i)/150}$
نادر-حیاتی	۵ درصد آیتم‌ها: ارزش ×۳۰، محبوبیت ×۰٫۱۵
ترکیبی	۵ درصد حیاتی (مانند بالا)؛ ۲۵ درصد پایدار (ایستا)؛ ۷۰ درصد گذرا ($\tau = 75$، محبوبیت ×۳)
رانش	۱۰ موضوع، محبوبیت ~ Dirichlet(0.5)، نمونه‌گیری مجدد در ۵ رژیم (۱ تا ۵۰ در بخش ۷.۵)
قاعده درخواست	آیتم $i \in A_t$ با احتمال $w_i(t)/\sum_{j\in A_t} w_j(t)$ انتخاب می‌شود
بودجه‌ها	اندازه کل جریان $B \in \{2.5, 5, 10, 20, 40\}\%$
بذرها	آزمون ۰ تا ۹؛ اعتبارسنجی ۱۰۰۰ تا ۱۰۰۴

ج. صورت‌بندی ILP اوراکل آفلاین

متغیرها: $y_{i,k} \in \{0,1\}$ برای هر آیتم i و هر یک از درخواست‌هایش $k = 1,\dots,K_i$ (به‌طور میانگین حدود ۲٬۱۰۰ متغیر در هر نمونه). تابع هدف: $\max \sum v_i y_{i,k}$. قیدها: (۱) برگشت‌ناپذیری $y_{i,k} - y_{i,k-1} \le 0$؛ (۲) ظرفیت $\sum_i s_i y_{i,\nu_i(t)} \le B$ در هر زمان ورود t، که وقتی نمی‌تواند فعال شود حذف می‌شود. با HiGHS (تابع `milp` در SciPy) با شکاف نسبی 10^{-4} و محدودیت زمانی ۹۰ ثانیه برای هر نمونه حل می‌شود. درستی آن در برابر شمارش کامل روی ۶۰ نمونه تصادفی تأیید شده است (`tests/test_oracle.py`).

د. نتایج تجربی تکمیلی

د.۱ پیمایش ظرفیت (میانگین روی بارهای کاری، کسری از OPT).

cap_frac	Ebbinghaus	FIFO	GDS	GenAgents	ImpDecay	LFU	LRU	Random	VRS	VRS+C
0.025	0.422	0.244	0.566	0.443	0.501	0.217	0.337	0.225	0.621	0.689
0.05	0.502	0.348	0.673	0.575	0.606	0.273	0.464	0.316	0.688	0.75
0.1	0.607	0.476	0.777	0.729	0.715	0.391	0.592	0.435	0.78	0.824
0.2	0.73	0.618	0.88	0.848	0.83	0.548	0.728	0.592	0.873	0.9
0.4	0.879	0.801	0.96	0.946	0.927	0.773	0.881	0.803	0.959	0.969

د.۲ پیمایش نویز ارزش (کسری از OPT).

	Ebbinghaus	FIFO	GDS	GenAgents	ImpDecay	LFU	LRU	Random	VRS	VRS+C
('irm', 0.0)	0.562	0.37	0.743	0.674	0.705	0.48	0.499	0.369	0.796	0.853
('irm', 0.25)	0.562	0.37	0.733	0.664	0.698	0.48	0.499	0.369	0.788	0.843
('irm', 0.5)	0.562	0.37	0.721	0.641	0.682	0.48	0.499	0.369	0.768	0.825
('irm', 1.0)	0.562	0.37	0.664	0.589	0.634	0.48	0.499	0.369	0.711	0.769
('irm', 1.5)	0.562	0.37	0.603	0.56	0.585	0.48	0.499	0.369	0.652	0.702
('irm', 2.0)	0.562	0.37	0.562	0.523	0.543	0.48	0.499	0.369	0.595	0.641
('mixed', 0.0)	0.587	0.402	0.848	0.82	0.776	0.349	0.563	0.375	0.84	0.866
('mixed', 0.25)	0.587	0.402	0.841	0.81	0.773	0.349	0.563	0.375	0.835	0.863
('mixed', 0.5)	0.587	0.402	0.833	0.806	0.759	0.349	0.563	0.375	0.824	0.853
('mixed', 1.0)	0.587	0.402	0.797	0.776	0.712	0.349	0.563	0.375	0.777	0.812
('mixed', 1.5)	0.587	0.402	0.719	0.735	0.652	0.349	0.563	0.375	0.736	0.758
('mixed', 2.0)	0.587	0.402	0.666	0.685	0.58	0.349	0.563	0.375	0.691	0.716
('rare_critical', 0.0)	0.55	0.366	0.754	0.693	0.709	0.491	0.509	0.35	0.799	0.846
('rare_critical', 0.25)	0.55	0.366	0.756	0.687	0.71	0.491	0.509	0.35	0.797	0.842
('rare_critical', 0.5)	0.55	0.366	0.742	0.677	0.704	0.491	0.509	0.35	0.786	0.829
('rare_critical', 1.0)	0.55	0.366	0.702	0.65	0.666	0.491	0.509	0.35	0.742	0.783
('rare_critical', 1.5)	0.55	0.366	0.65	0.61	0.629	0.491	0.509	0.35	0.687	0.732
('rare_critical', 2.0)	0.55	0.366	0.607	0.569	0.575	0.491	0.509	0.35	0.645	0.675

د.۳ پیمایش رانش (کسری از OPT).

ov_n_phases	Ebbinghaus	FIFO	GDS	GenAgents	ImpDecay	LFU	LRU	Random	VRS	VRS+C
1	0.67	0.336	0.726	0.663	0.731	0.604	0.55	0.325	0.772	0.819
2	0.597	0.353	0.707	0.646	0.673	0.526	0.538	0.35	0.74	0.794
5	0.511	0.357	0.683	0.618	0.64	0.44	0.486	0.367	0.738	0.793
10	0.503	0.365	0.686	0.604	0.633	0.445	0.441	0.355	0.736	0.797
20	0.513	0.365	0.689	0.612	0.651	0.441	0.461	0.356	0.746	0.804
50	0.541	0.369	0.703	0.616	0.667	0.433	0.454	0.374	0.758	0.818

د.۴ زمان اجرا (میکروثانیه برای هر رویداد، پیاده‌سازی مرجع پایتون، اندازه‌گیری‌شده با ۲۴ پردازه هم‌زمان).

policy	us_per_event
Ebbinghaus	41.1
FIFO	14.1
GDS	16.8
GenAgents	80.5
GenAgents+C	362.2
ImpDecay	45.4
LFU	21.1
LRU	14.7
LRU+C	42.5
Random	5.5
VRS	158.5
VRS+C	447.2
VRS-noRate	27.5
VRS-noSize	136.6
VRS-noValue	164.4

زمان‌های اجرا تحت تأثیر پیمایش حافظه در سطح پایتون در هر حذف‌اند؛ پیاده‌سازی مبتنی بر هیپ VRS را به $O(\log |M|)$ برای هر عملیات کاهش می‌دهد.

د.۵ LoCoMo، پروتکل پایانی (درصد OPT، میانگین ± انحراف معیار روی ۱۰ مکالمه).

Policy	B = 5%	B = 10%	B = 20%	B = 40%	Evidence recall @10%
Random	10.4 ± 4.1	14.4 ± 3.8	21.5 ± 4.1	37.8 ± 3.3	7.9%
FIFO	10.3 ± 4.4	16.4 ± 5.3	22.4 ± 4.1	36.6 ± 4.1	8.9%
LRU	10.3 ± 4.4	16.4 ± 5.3	22.4 ± 4.1	36.6 ± 4.1	8.9%
LFU	10.3 ± 4.4	16.4 ± 5.3	22.4 ± 4.1	36.6 ± 4.1	8.9%
GDS	25.9 ± 7.4	34.8 ± 6.2	49.2 ± 5.7	71.5 ± 7.3	19.3%
Ebbinghaus	10.3 ± 4.4	16.4 ± 5.3	22.4 ± 4.1	36.6 ± 4.1	8.9%
GenAgents	23.8 ± 8.6	28.6 ± 4.2	40.1 ± 6.8	65.0 ± 7.3	15.7%
ImpDecay	26.7 ± 6.2	35.7 ± 7.0	45.1 ± 5.2	67.7 ± 8.2	19.7%
VRS	38.7 ± 7.5	47.0 ± 7.0	53.9 ± 6.8	73.5 ± 7.4	26.0%
VRS+C	**58.5 ± 5.9**	64.5 ± 7.5	67.9 ± 5.8	**77.0 ± 6.7**	47.4%
GenAgents+C	55.1 ± 8.7	**70.5 ± 8.7**	**69.1 ± 6.4**	75.1 ± 4.9	63.4%
LRU+C	10.6 ± 4.1	16.4 ± 5.3	22.6 ± 4.0	36.7 ± 4.1	9.0%
VRS-noRate	45.3 ± 9.7	48.7 ± 7.1	56.6 ± 6.6	73.5 ± 6.8	26.9%
VRS-noValue	8.7 ± 5.3	10.9 ± 4.7	16.4 ± 3.8	30.4 ± 4.0	5.9%
VRS-noSize	31.0 ± 8.7	39.6 ± 7.6	49.1 ± 6.0	72.0 ± 6.9	21.9%
VRS (no LLM)	8.7 ± 5.3	10.9 ± 4.7	16.4 ± 3.8	30.4 ± 4.0	5.9%
GDS (no LLM)	8.7 ± 3.5	13.5 ± 3.8	18.7 ± 3.8	33.0 ± 4.7	7.3%
GenAgents (no LLM)	10.3 ± 4.4	16.4 ± 5.3	22.4 ± 4.1	36.6 ± 4.1	8.9%

د.۶ آزمون‌های رتبه‌علامت‌دار Wilcoxon جفتی، بارهای کاری مصنوعی. اختلاف مثبت به نفع سیاست A است.

scope	A	B	n	mean_diff_pt	win_rate	p_value
all budgets, all workloads	VRS+C	GDS	250	5.51	78%	2.7e-17
all budgets, all workloads	VRS+C	VRS	250	4.24	100%	5.1e-42
all budgets, all workloads	VRS	GDS	250	1.27	62%	0.00062
all budgets, all workloads	VRS	GenAgents	250	7.58	79%	6.4e-18
all budgets, all workloads	VRS	ImpDecay	250	6.81	86%	7.4e-37
all budgets, all workloads	GDS	LRU	250	17.12	90%	1.1e-40
all budgets, all workloads	GenAgents	LRU	250	10.81	90%	2.9e-40
all budgets, all workloads	LRU	Random	250	12.6	99%	2.1e-42
all budgets, all workloads	Ebbinghaus	Random	250	15.38	100%	9.5e-43
B = 10%	VRS+C	GDS	50	4.64	76%	0.00012
B = 10%	VRS+C	VRS	50	4.34	100%	1.8e-15
B = 10%	VRS	GDS	50	0.3	62%	0.22
B = 10%	VRS	GenAgents	50	5.08	78%	0.0011
IRM (stationary), all budgets	VRS	GDS	50	6.51	92%	1.1e-12
Temporal locality, all budgets	VRS	GDS	50	-9.81	0%	1.8e-15
Rare-critical, all budgets	VRS	GDS	50	4.39	92%	2.2e-12
Drift, all budgets	VRS	GDS	50	5.07	96%	5.9e-14
Mixed assistant, all budgets	VRS	GDS	50	0.17	28%	0.062

د.۷ آزمون‌های رتبه‌علامت‌دار Wilcoxon جفتی، LoCoMo.

scope	A	B	n	mean_diff_pt	win_rate	p_value
interleaved, all budgets	VRS	GDS	400	-1.34	31%	5e-14
interleaved, all budgets	VRS+C	GDS	400	6.86	96%	2.8e-66
interleaved, all budgets	VRS+C	VRS	400	8.19	99%	4.1e-67
interleaved, all budgets	VRS	GenAgents	400	1.27	61%	1.6e-08
interleaved, all budgets	VRS	LRU	400	13.5	98%	1.1e-66
interleaved, all budgets	GDS	LRU	400	14.84	100%	2.8e-67
interleaved, all budgets	VRS	VRS (no LLM)	400	24.52	100%	2.7e-67
interleaved, all budgets	GDS	GDS (no LLM)	400	19.75	100%	2.7e-67
interleaved, all budgets	GenAgents	GenAgents (no LLM)	400	12.23	98%	1.4e-66
end, all budgets	VRS	GDS	40	7.9	90%	2e-07
end, all budgets	VRS+C	GDS	40	21.62	100%	1.8e-12
end, all budgets	VRS+C	VRS	40	13.72	100%	1.8e-12
end, all budgets	VRS	GenAgents	40	13.89	100%	1.8e-12
end, all budgets	VRS	LRU	40	31.84	100%	3.6e-08
end, all budgets	GDS	LRU	40	23.94	95%	9.1e-12

د.۸ بهای پیش‌آگاهی (شبیه‌سازی $\mathbb{E}[\mathrm{OPT}]/\mathbb{E}[\mathrm{DENSITY}]$؛ ستون‌ها: (n, B)).

req_per_item	(100, 1)	(100, 10)	(1000, 1)	(1000, 10)
0.25	8.661	5.105	12.103	8.917
0.5	5.912	4.032	8.024	6.363
1	4.222	3.003	5.504	4.429
2	3.151	2.362	3.974	3.291
4	2.456	1.945	2.97	2.543
8	1.989	1.652	2.328	2.049
16	1.681	1.454	1.901	1.721
32	1.468	1.316	1.619	1.498
64	1.328	1.222	1.429	1.347
128	1.229	1.156	1.299	1.242
256	1.16	1.109	1.209	1.169

د.۹ تحلیل حساسیت. پارامترهای فشرده‌سازی (میانگین روی بارهای کاری در $B = 10\%$، کسری از OPT فقط-حذف؛ سطرها: (ρ, γ)):

	GDS+C	GenAgents+C	VRS+C
(0.1, 0.3)	0.757	0.723	0.808
(0.1, 0.6)	0.869	0.857	0.891
(0.1, 0.9)	1.005	1.012	0.992
(0.25, 0.3)	0.766	0.73	0.781
(0.25, 0.6)	0.81	0.765	0.824
(0.25, 0.9)	0.936	0.935	0.904
(0.5, 0.6)	0.776	0.737	0.783
(0.5, 0.9)	0.845	0.82	0.821

توزیع‌های بار کاری (کسری از OPT در $B = 10\%$؛ هر سطر یک پارامتر را نسبت به مقدار پیش‌فرض تغییر می‌دهد):

	LRU	Ebbinghaus	GenAgents	GDS	VRS	VRS+C	best
('irm', 'rate_shape=1.1')	0.621	0.693	0.713	0.761	0.784	0.835	VRS+C
('irm', 'rate_shape=1.5')	0.499	0.562	0.641	0.721	0.768	0.825	VRS+C
('irm', 'rate_shape=3.0')	0.415	0.431	0.62	0.705	0.758	0.827	VRS+C
('irm', 'size_sigma=0.3')	0.512	0.572	0.653	0.681	0.737	0.802	VRS+C
('irm', 'size_sigma=0.6')	0.499	0.562	0.641	0.721	0.768	0.825	VRS+C
('irm', 'size_sigma=1.0')	0.486	0.553	0.622	0.781	0.814	0.858	VRS+C
('irm', 'value_sigma=0.5')	0.537	0.603	0.563	0.64	0.701	0.784	VRS+C
('irm', 'value_sigma=1.0')	0.499	0.562	0.641	0.721	0.768	0.825	VRS+C
('irm', 'value_sigma=2.0')	0.465	0.52	0.849	0.886	0.905	0.923	VRS+C
('mixed', 'critical_value_mult=10.0')	0.644	0.684	0.766	0.804	0.788	0.825	VRS+C
('mixed', 'critical_value_mult=100.0')	0.427	0.424	0.883	0.896	0.891	0.909	VRS+C
('mixed', 'critical_value_mult=30.0')	0.563	0.587	0.806	0.833	0.824	0.853	VRS+C
('mixed', 'rate_shape=1.1')	0.658	0.68	0.855	0.867	0.86	0.88	VRS+C
('mixed', 'rate_shape=1.5')	0.563	0.587	0.806	0.833	0.824	0.853	VRS+C
('mixed', 'rate_shape=3.0')	0.489	0.477	0.76	0.81	0.795	0.828	VRS+C
('mixed', 'size_sigma=0.3')	0.566	0.585	0.805	0.821	0.804	0.837	VRS+C
('mixed', 'size_sigma=0.6')	0.563	0.587	0.806	0.833	0.824	0.853	VRS+C
('mixed', 'size_sigma=1.0')	0.558	0.589	0.805	0.866	0.854	0.876	VRS+C
('mixed', 'value_sigma=0.5')	0.544	0.564	0.775	0.8	0.784	0.818	VRS+C
('mixed', 'value_sigma=1.0')	0.563	0.587	0.806	0.833	0.824	0.853	VRS+C
('mixed', 'value_sigma=2.0')	0.601	0.631	0.888	0.925	0.924	0.936	VRS+C

۵. ابرپارامترهای روش‌های مبنا

ابرپارامترها با جستجوی شبکه‌ای روی بذرهای اعتبارسنجی ۱۰۰۰ تا ۱۰۰۴ در $B = 10\%$ و با بیشینه‌سازی میانگین نسبت مطلوبیت روی پنج بار کاری انتخاب شدند. همین رویه برای هر سیاست قابل‌تنظیم اعمال شد. FIFO، LFU، LRU، GDS و Random ابرپارامتری ندارند.

سیاست	شبکه	انتخاب‌شده	درصد OPT در اعتبارسنجی
Ebbinghaus	$S_0 \in \{25, \dots, 1600\}$	۲۵ (همه مقادیر برابرند)	59.1
GenAgents	$\delta \in \{0.95, 0.98, 0.99, 0.995, 0.998, 0.999, 0.9995\}$ زوال	0.99	75.1
ImpDecay	$S_0 \in \{25, 50, 100, 200, 400, 800, 1600\}$	200	—
VRS	$b_0 \in \{50, 200, 800\}$، نیمه‌عمر $h \in \{100, 300, 1000, 3000, \infty\}$	$b_0 = 50$، $h = 100$	78.0

نکته *درباره Ebbinghaus*. امتیاز ماندگاری آن $e^{-\Delta t/(S_0(1+n))}$ تابعی یکنوا از $\Delta t/(1+n)$ است، پس ترتیب حذف، و در نتیجه عملکرد، نسبت به S_0 ناوردا است. VRS با تخمین‌گر ایستا ($h = \infty$، $b_0 = 50$) در اعتبارسنجی به ۷۳٫۲ درصد می‌رسد، ۴٫۸ واحد کمتر از تخمین‌گر تنزیل‌شده؛ نتایج کامل در `results/tuning.csv` است.

و. پرامپت پیش‌بینی اهمیت توسط LLM

هر جلسه LoCoMo یک بار به مدل فرستاده می‌شود (Gemini 2.5 Flash از طریق نقطه پایانی سازگار با OpenAI، دمای ۰). مدل هرگز هیچ پرسشی را نمی‌بیند. پاسخ‌هایی که دقیقاً یک عدد صحیح برای هر نوبت ندارند تا پنج بار دوباره درخواست می‌شوند؛ اگر باز هم ناموفق باشند، جلسه دو نیم شده و هر نیمه جداگانه امتیاز می‌گیرد. همه ۲۷۲ جلسه (۵,۸۸۲ نوبت) امتیاز گرفتند.

```
You manage the long-term memory of a personal AI assistant that will later be asked
questions about the two speakers below (facts about their lives, events, dates, plans,
preferences, relationships). Memory is limited, so some conversation turns will be forgotten.

For EACH numbered turn of the session below, rate from 1 to 10 how important it is to keep
in memory because it is likely to be needed to answer future questions (10 = essential
personal fact or event, 1 = small talk with no lasting information). Judge each turn only
by its content.

Session date: {date}
{numbered turns}

Respond with ONLY a JSON array of {n} integers, one per turn, in order.
```

کالیبراسیون روی LoCoMo (کسری از نوبت‌ها با هر امتیاز که بعداً به‌عنوان شاهد لازم می‌شوند):

امتیاز	1	2	3	4	5	6	7	8	9	10
تعداد نوبت‌ها	1291	1303	640	294	275	336	486	651	462	144
بعداً لازم شده	3.4%	7.2%	14.8%	18.7%	26.2%	27.4%	44.0%	54.7%	66.0%	70.1%

AUC برای جداسازی نوبت‌های شاهد از غیرشاهد: ۰٫۸۲۵.